

Logistic回归练习题

数据科学导论（2024-2025秋季学期）

2024年11月13日

1 提交要求

- 请提交一个文件（仅限docx或pdf格式）；
- 标清小题题号，依次作答；
- 既可手写解题过程后拍照，也可直接使用编辑软件给出结果；
- 提交截止：11月21日23:55

2 题目内容（包含4道必做题和4道附加题）

习题:对某一实际二分类问题,我们收集到 n 个样本 $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$,我们考虑对其使用Logistic回归,其中 $\mathbf{x} \in \mathbb{R}^d$ 为自变量特征向量, $y \in \{0, 1\}$ 为可能的两个类,我们考虑如下几个问题.

1): 取 $\boldsymbol{\theta} \in \mathbb{R}^d$ 为参数向量, 记Logistic回归模型为 $f_{\boldsymbol{\theta}}(\mathbf{x})$. 请给出你设计的模型 $f_{\boldsymbol{\theta}}(\mathbf{x})$ 下输出的预测样本 $\mathbf{x}$ 被分到第1类的概率 $P_{\boldsymbol{\theta}}(y = 1 | \mathbf{x})$. 同时, 请画出概率 $P_{\boldsymbol{\theta}}(y = 1 | \mathbf{x})$ 与变量 $\boldsymbol{\theta}^T \mathbf{x}$ 之间的关系曲线的大致形状.

2): 请解释为什么Logistic回归要选取模型 $f_{\boldsymbol{\theta}}(\mathbf{x})$?(提示: 可以上一问题中 $P_{\boldsymbol{\theta}}(y = 1 | \mathbf{x})$ 曲线的特性)

3): 假设 $n = 100$, 经过Logistic回归后的分类结果和真实结果如下表所示(其中 y 和 $\hat{y}$ 分别表示真实值和预测值), 请评价此次分类结果效果如何.

	$y = 1$	$y = 0$
$\hat{y} = 1$	45	12
$\hat{y} = 0$	5	38

Table 1: 分类结果

4): 如上, 在样本上 $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ 对模型 $f_{\boldsymbol{\theta}}(\mathbf{x})$ 做Logistic回归, 请写出参数 $\boldsymbol{\theta}_t$ 在梯度下降算法下的更新公式.

附加题:

5): 仿造二分类任务, 假设对 m 分类Logistic回归任务, 请查阅资料给出 m 分类任务下(Cross-Entropy) Loss的形式(考虑参数 $(\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_m)$, 对 $(\sigma(\boldsymbol{\theta}_1^T \mathbf{x}), \dots, \sigma(\boldsymbol{\theta}_m^T \mathbf{x}))$ 进行建模)

6): 对于两个概率分布函数 P, Q , 他们之间的Kullback–Leibler divergence (KL)散度被定义为 $D_{KL}(P \parallel Q) = \int P \log \frac{P}{Q}(\mathbf{x}) d\mathbf{x}$. 请说明在什么情况下 $D_{KL}(P \parallel Q) = 0$. 更进一步的, 假设我们能参数化模拟概率模型 P_{θ} , 并希望用它逼近 P , 请思考, 我们应该如何设计损失函数.

7): 接上一小问, 已知为估计某随机变量 $\mathbf{X}$ 期望的 $\mathbb{E}[\mathbf{X}] = \int P_{\mathbf{X}}(\mathbf{x}) \mathbf{x} d\mathbf{x}$ ($P_{\mathbf{X}}$ 为 $\mathbf{X}$ 的分布函数), 我们可以考虑用样本均值 $\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$ 代替, 这里 $\{\mathbf{x}_i\}_{i=1}^n$ 为从 $P_{\mathbf{X}}$ 中采样的样本. 一般来说, 为估计 $P_{\mathbf{X}}$, 我们考虑参数化模型 P_{θ} , 并构造如下极大似然估计损失(MLE)

$$\max_{\theta} \sum_{i=1}^n \log P_{\theta}(\mathbf{x}_i). \quad (1)$$

请解释MLE损失和KL散度之间的关系.

8): 对于5)中的多分类问题, 假设对自变量 $\mathbf{x}$ 概率模型 $P_{\theta}(\mathbf{x}) = P(\mathbf{x})$. 请说明在此设定下Cross-Entropy损失和极小化KL散度 $D_{KL}(P(\mathbf{x}, y) \parallel P_{\theta}(\mathbf{x}, y))$ 之间的关系. ($P(\mathbf{x}, y)$ 为真实数据 $(\mathbf{x}, y)$ 的联合分布). (提示:考虑条件概率公式)