

$$\{(x_i, y_i)\}_{i=1}^n \quad x_i \in \mathbb{R}^d \quad d \leq n. \quad y_i \in \mathbb{R}$$

$$\|x\| = \sqrt{\sum_{i=1}^n x_i^2}$$

L2范数

$$X = (x_1^T, x_2^T, \dots, x_n^T)^T \in \mathbb{R}^{n \times d} \quad \text{rank}(X) = d$$

$$y = (y_1, \dots, y_n)^T \in \mathbb{R}^n$$

$$\min_{\theta} f(\theta) = \min_{\theta} \frac{1}{2} \|X\theta - y\|^2$$

$$\theta = (\theta_1, \dots, \theta_d)^T \in \mathbb{R}^d$$

$$f(\theta) : \mathbb{R}^d \rightarrow \mathbb{R} \quad \text{梯度 } \nabla f(\theta) = \left(\frac{\partial f}{\partial \theta_1}, \dots, \frac{\partial f}{\partial \theta_n} \right)^T$$

$$(x_1\theta - y_1, x_2\theta - y_2, \dots, x_n\theta - y_n)$$

$$\min_{\theta} f(\theta) = \min_{\theta} \frac{1}{2} \sqrt{(x_1\theta - y_1)^2 + \dots + (x_n\theta - y_n)^2}$$

T1. $f(\theta) = \frac{1}{2} \|x\theta - y\|^2$ $x\theta - y$ 是一个列向量: $(x_1\theta - y_1, \dots, x_n\theta - y_n)$

$= \frac{1}{2} (x\theta - y)^T (x\theta - y)$ 利用 $(a-b)^T(a-b) = a^T a - 2a^T b + b^T b$

$= \frac{1}{2} ((x\theta)^T x\theta - 2(x\theta)^T y + y^T y)$

$= \frac{1}{2} \theta^T x^T x \theta - \theta^T x^T y + \frac{1}{2} y^T y$

$\frac{\partial (\theta^T A \theta)}{\partial \theta} = 2A\theta$ (二次型)

线性求导 常数求导

接着求导. $\nabla f(\theta) = \frac{1}{2} \cdot 2 \cdot x^T x \theta - x^T y + 0$
(对 θ) $= x^T x \theta - x^T y$

T₂. $\theta_{t+1} = \theta_t - \alpha \nabla f(\theta)$

因此更新公式为 $\theta - \alpha (x^T x \theta - x^T y)$

T₃. 最优解对应 $\nabla f(\theta) = 0$ 即 $x^T x \theta - x^T y = 0$

故 $x^T x \theta = x^T y$
此时需 $x^T x$ 可逆 $\theta^* = (x^T x)^{-1} x^T y$

$$T_4. \quad \begin{cases} \theta_{t+1} = \theta_t - \alpha (x^T x \theta_t - x^T y) \\ \theta^* = (x^T x)^{-1} x^T y \end{cases}$$

代入得 $\theta_{t+1} = \theta_t - \alpha (x^T x \theta_t - x^T x \theta^*) = \theta_t - \alpha x^T x (\theta_t - \theta^*)$

$$(\theta_{t+1} - \theta^*) = (\theta_t - \theta^*) - \alpha x^T x (\theta_t - \theta^*) = (E - \alpha x^T x) (\theta_t - \theta^*)$$

我们要使 $\Delta = \theta_t - \theta^* \rightarrow 0$ 在 $t \rightarrow \infty$. 设 $x^T x$ 最大特征值为 $\lambda_{\max}$.

这里需 $E - \alpha x^T x$ 所有特征值绝对值 < 1 因此有 $|1 - \alpha \lambda_{\max}| < 1$

解得 $0 < \alpha < \frac{2}{\lambda_{\max}}$. 在此区间取学习率可以使误差逐步减小,
从而得最优解 θ^*

T5 $A^2=A \Rightarrow A(A-I)=0$ 得 A 特征值为 0 或 1

又 $\because A$ 为对称矩阵

$\therefore A$ 可以对角化. 即 $A=U\Lambda U^T$. Λ 为对角矩阵.
对角线元素为 0 或 1

$\forall a \in \text{span}\{a_1, \dots, a_n\}$. 有 $a = \lambda_1 a_1 + \dots + \lambda_n a_n$

$$Aa = A(\lambda_1 a_1 + \dots + \lambda_n a_n) = \lambda_1 Aa_1 + \dots + \lambda_n Aa_n$$

利用 $Aa_i = a_i$ (因为 A 的列向量是 A 的特征向量, 对应特征值为 1)

$$= \lambda_1 a_1 + \dots + \lambda_n a_n = a$$

故得证 $\#$

列向量
 $\uparrow$
 $A \cdot A = A$

T6. $\text{span}\{a_1, \dots, a_n\}$ 是 A 的列空间

由正交性质, $\mathbb{R}^n = \text{span}\{a_1, \dots, a_n\} \oplus \text{span}\{a_1, \dots, a_n\}^\perp$

取 $b_1 \in \text{span}\{a_1, \dots, a_n\}$

$b_2 \in \text{span}\{a_1, \dots, a_n\}^\perp$

则 $b_2 \perp \text{span}\{a_1, \dots, a_n\}$

故 $\forall a \ \exists b_1 + b_2 = a$

#

T

先证 P_X 为投影矩阵 $(\Rightarrow P_X^2 = P_X$ 且 $P_X^T = P_X$

$$P_X^2 = X \underbrace{(X^T X)^{-1} X^T}_I X (X^T X)^{-1} X^T = X (X^T X)^{-1} X^T = P_X$$

$$\begin{aligned} P_X^T &= (X (X^T X)^{-1} X^T)^T = X (X^T X)^{-T} X^T = X ((X^T)^T)^T (X^T)^T X^T \\ &= X X^T (X^T)^T X^T = X (X^T X)^{-1} X^T \\ &= P_X \end{aligned}$$

故 P_X 为投影矩阵

$$P_X a = X (X^T X)^{-1} X^T a = X [(X^T X)^{-1} X^T a]$$

是 X 列向量的线性组合。
因此 $\beta \in \text{span}\{x_1, \dots, x_d\}$

$$\hat{y} = X \theta^* = [X (X^T X)^{-1} X^T] y \quad (\text{由前述结论})$$

因此 $\hat{y} = P_X y \in \text{span}\{\tilde{x}_1, \dots, \tilde{x}_d\}$ P_X 是投影矩阵。
 $P_X y$ 为 y 在 $\text{span}\{\tilde{x}_1, \dots, \tilde{x}_d\}$ 上的投影

#