



$$T_1 \quad f_{\theta}(x) = \sigma(\theta^T x) \quad \sigma(t) = \frac{1}{1 + e^{-t}}$$

$$P_0(y=1|x) = f_{\theta}(x) = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

关系是 S 型曲线



T₂ ① 参数 θ 具有解释性

若 θ 为正, 则 x_i 为 $P(y=1|x)$ 有正向影响, 故 x_i 越大, 样本越可能被分为正类.

反之若 θ 为负, x_i 越大则越可能被分为负类.

$\theta=0$ 不影响分类结果

同时, $|\theta|$ 越大对分类结果影响越显著

② Sigmoid 函数可以将输出映射在 $[0, 1]$ 上

有利于解决分类问题

T3

1° 计算精确度

TP=45	FN=5
FP=12	TN=38

$$\text{Precision} = \frac{TP}{TP+FP} = \frac{45}{57} \approx 0.789$$

2° 计算召回率

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{45}{45+5} = 0.9$$

3° 计算 F1

$$F_1 = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}} = \frac{2 \times 0.789 \times 0.9}{0.789 + 0.9} \approx 0.841$$

4⁰ 计算准确率

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN} = \frac{45 + 38}{45 + 38 + 12 + 5} = 0.83$$

综合以上指标，该分类效果较好。

T_4 使用对数似然函数的负对数作为损失函数

(交叉熵损失函数)

$$L(\theta, x, y) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{y}_i + (1-y_i) \log (1-\hat{y}_i)]$$

$$\text{其中 } \hat{y}_i = f_{\theta}(x_i) = \sigma(\theta^T x_i) = P_{\theta}(y=1|x_i)$$

梯度下降更新公式: $\forall \theta_j$, 有 $\theta_j^{(t+1)} = \theta_j^{(t)} - \alpha \frac{\partial L(\theta, x, y)}{\partial \theta_j}$

$$\alpha \text{ 为学习率. } \frac{\partial L(\theta, x, y)}{\partial \theta_j} = \frac{1}{n} \sum_{i=1}^n (\sigma(\theta^T x_i) - y_i) \cdot x_{ij}$$

$$\text{故更新公式为 } \theta_j^{(t+1)} = \theta_j^{(t)} - \frac{\alpha}{n} \sum_{i=1}^n (\sigma(\theta^T x_i) - y_i) x_{ij}$$

TS 对于 m 分类, 需先计算每个 $i \in \{1, 2, \dots, m\}$ 的预测类别概率

$$P\{y=i|x\} = \sigma(\theta_i^T x) = \frac{1}{1 + e^{-\theta_i^T x}}$$

$$\text{损失函数 } L(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^m [y_{ij} \log \sigma(\theta_j^T x_i) + (1 - y_{ij}) \log (1 - \sigma(\theta_j^T x_i))]$$

先对 m 个类别求 Cross-Entropy

再对 N 个总样本数进行计算

$$T_6 \quad D_{KL}(P \parallel Q) = \int P(x) \log \frac{P(x)}{Q(x)} dx$$

$P(x)$ 为目标分布
 $Q(x) = P_0(x)$ 为模型分布

当且仅当 $\frac{P(x)}{Q(x)} = 1$ 即 $P(x) = Q(x)$ 对所有 x 成立时, $D_{KL}(P \parallel Q) = 0$

$$D_{KL}(P \parallel Q) = \underbrace{\int P(x) \log P(x) dx}_{\text{与 } Q \text{ 无关}} - \underbrace{\int P(x) \log P_0(x) dx}_{\text{对数似然函数}}$$

将 $P_0(x)$ 逼近 $P(x)$ 实质是想让 $\frac{P(x)}{P_0(x)} \rightarrow 1$. 因而 $D_{KL}(P \parallel Q) \rightarrow 0$

由 $D_{KL}(P \parallel Q)$ 的非负性知我们需 **最大化** 对数似然函数

因此损失函数可被定义为 $-\int P(x) \log P_0(x) dx$

$$T_7 \quad \text{MLE} = \max_{\theta} \sum_{i=1}^n \log P_{\theta}(x_i)$$

$$D_{KL}(P||Q) = \int p(x) \log p(x) dx - \underline{\int p(x) \log P_{\theta}(x) dx}$$

KL散度的损失函数，可以发现其与MLE等价

$$-\int p(x) \log P_{\theta}(x) dx = -\frac{1}{n} \sum \log P_{\theta}(x_i) = D_{KL}(P||P_{\theta})$$

因此此时，MLE最大等价于KL散度最小。

$$T8 \quad D_{KL}(P(x,y) \parallel P_{\theta}(x,y)) = E \left(P(x,y) \left[\log \frac{P(x,y)}{P_{\theta}(x,y)} \right] \right)$$

$$= \underbrace{E(P(x,y) \log P(x,y))}_{\text{熵项}} - \underbrace{E(P(x,y) \log P_{\theta}(x,y))}_{\text{对数似然损失 (Cross-Entropy) } L(\theta)}$$

熵项

对数似然损失 (Cross-Entropy) $L(\theta)$

利用条件概率:

$$L(\theta) = - E(P(x,y) \log P_{\theta}(x,y)) = - E(P(x,y) (\log P(x) + \log P_{\theta}(y|x)))$$

$$\text{利用 } P(x,y) = P(x) P(y|x), P_{\theta}(x,y) = P(x) P_{\theta}(y|x)$$

$$= \underbrace{- E(P(x,y) \log P(x))}_{\text{熵项}} - E(P(x,y) \log P_{\theta}(y|x))$$

熵项

因此KL散度等价于极小化 Cross-Entropy 损失