

本周五（11日）有上机课

- 18:00-20:15



- 理工配楼二层 1、2 机房

第 4 讲：探索数据分析 – 数据可视化

“数据科学导论”专业核心课



范举 教授

fanj@ruc.edu.cn



提纲




探索数据分析 - 可视化

- 1. 探索数据分析
- 2. 数据可视化
- 3. 复习：数据探索的基本操作
- 4. 课堂练习与研讨

数据分析的目标：让数据

- 数据自己不会说话，需要数据科学家帮它
- Data $\square$ Insight
- 原则一：要说人话
 - 从数据中得到人们容易理解的结论
- 原则二：不说废话
 - 得到的结论需要有信息增量






如何用数据支撑自己的观点



- 案例：全世界各国的温室气体排放数据

```
co2 = pd.read_csv('../Datasets/co2-data/owid-co2-data.csv')
co2
```

	iso_code	country	year	co2	consumption_co2	co2_growth_prct	co2_growth_abs	trad
0	AFG	Afghanistan	1949	0.015	NaN	NaN	NaN	
1	AFG	Afghanistan	1950	0.084	NaN	475.00	0.070	
2	AFG	Afghanistan	1951	0.092	NaN	8.70	0.007	
3	AFG	Afghanistan	1952	0.092	NaN	0.00	0.000	
4	AFG	Afghanistan	1953	0.106	NaN	16.00	0.015	
...	...	...	...	...	...	...	...	...
25199	ZWE	Zimbabwe	2016	10.738	12.153	-12.17	-1.488	
25200	ZWE	Zimbabwe	2017	9.582	11.248	-10.77	-1.156	
25201	ZWE	Zimbabwe	2018	11.854	13.163	23.72	2.273	
25202	ZWE	Zimbabwe	2019	10.949	12.422	-7.64	-0.905	
25203	ZWE	Zimbabwe	2020	10.531	NaN	-3.82	-0.418	



【谁该为气候变化买单？-- 谁应该解决它？】

https://www.bilibili.com/video/BV1DP411z7g5/?share_source=copy_web&vd_source=61162fa3cae46557c8656dee5b330347

探索数据分析：思维方式


- 大胆地假设：学会从数据中挖掘信息，从不同的角度或层次提出问题
 - 最普遍的方式：阐明现象，分析原因，提出改进，等等
- 小心地求证：多途径获取数据，多维度探索数据，多角度可视化数据，多学科知识解读数据



Exploratory data analysis is an attitude, a state of flexibility, a willingness to look for those things that we believe are not there, as well as those that we believe to be there

From John Turkey

探索数据分析：迭代 workflow






提纲




探索数据分析 - 可视化

- 1. 探索式数据分析
- 2. 数据可视化
- 3. 复习：数据探索的基本操作
- 4. 课堂练习与研讨

可视化的目标是让人发现规律



看上去年纪更大的人
并没有比年轻人花费
更多的金额





可视化：基本图表类型




- 单变量典型图表
 - 点阵图 - Dot plot
 - 直方图 - Histogram
 - 累积分布函数 - Cumulative distribution function
 - 箱线图 - Box plot
- 多变量典型图表
 - 柱状图 - Bar chart
 - 散布图 - Scatter plot
 - 线条图 - Line plot



散点图 (Scatter)

- 散点图将所有的数据以点的形式展现在直角坐标系上

Revenue
2000
11000
5400
204944
32244
1232
...





散点图的示例





- 分析某个购物中心的客户数据

```
import pandas as pd
```

```
dataset = pd.read_csv('./Mall_Customers.csv')  
dataset.head(10)
```

	CustomerID	Gender	Age	Annual Income (k\$)	Spending Score (1-100)
0	1	Male	19	15	39
1	2	Male	21	15	81
2	3	Female	20	16	6
3	4	Female	23	16	77
4	5	Female	31	17	40
5	6	Female	22	17	76
6	7	Female	35	18	6
7	8	Female	23	18	94
8	9	Male	64	19	3
9	10	Female	30	19	72





散点图的示例





- 分析某个购物中心的客户数据

```
import pandas as pd
```

```
dataset = pd.read_csv('./Mall_Customers.csv')  
dataset.head(10)
```


	CustomerID	Gender	Age	Annual Income (k\$)	Spending Score (1-100)
0	1	Male	19	15	39
1	2	Male	21	15	81
2	3	Female	20	16	6
3	4	Female	23	16	77
4	5	Female	31	17	40
5	6	Female	22	17	76
6	7	Female	35	18	6
7	8	Female	23	18	94
8	9	Male	64	19	3
9	10	Female	30	19	72



直方图 (Histogram)

- 直方图表示了数据在各组的**频数**分布情况

Revenue
2000
11000
5400
204944
32244
1232
...




在绘制 **40** 个企业营收的直方图时，这些企业的营收落在了 **4** 个桶中。如果第一、二、三组的频数分别是 **5**、**8**、**15**，则第四组的频数是多少？

- A. 12
- B. 40
- C. 15

直方图的局限性

- 如何分桶 (binning) 会带来很大的视觉差异




Data is like people – interrogate it hard enough and it will tell you whatever you want to hear.



累积分布函数


- 对于连续变量 x , 累积分布函数定义如下 : $F_X(x) = P(X \leq x)$.
- 离散变量 : 所有小于等于 a 的值出现概率的和

Revenue
2000
11000
5400
204944
32244
1232
...





累计分布图的示例




左侧的红色、蓝色、
橙色、绿色的四条线
分别代表了：

- A. 惜春**
- B. 迎春**
- C. 探春**
- D. 元春**

箱线图

- 通过图形的方式表示数据的
 - Min, 25% Quartile, Median, 75% Quartile, Max





箱线图



- Find the median, lower quartile and upper quartile of the following numbers.

- The **median** divides the data into a lower half and an upper half.

The **lower quartile** is the middle value of the lower half.

The **upper quartile** is the middle value of the upper half.



课堂练习

现有一组数值: [11, 17, 23, 15, 16, 37, 56]。

(1) 请计算其中位数 (median)、下四分位点 (lower quartile, 简称 Q1) 和上四分位点 (upper quartile, 简称 Q3), 并列出具体的算式。(2 分)


(2) 如果按照区间 $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ 来判断是否存在离群值 (Outliers), 请说明这组数值是否存在离群值, 并解释原因。注: $IQR = Q3 - Q1$ 。(3 分)

提示: 计算四分位数时, 首先要确定四分位数的位置, 然后根据位置计算相应的数值 (假设位置从 1 开始)。假设数据个数为 n , 一种常用的计算方法 (即 Excel 中的 QUARTILE.INC 函数) 按照以下公式计算四分位数的位置: $1 + (n - 1)/4$ 、 $1 + 2(n - 1)/4$ 、 $1 + 3(n - 1)/4$ 。若四分位数的位置不是整数, 则四分位数等于前后两个数的加权平均。例如, 如果下四分数的位置是 $2\frac{1}{4}$, 则下四分位数应为位置为 2 的数值 $+\frac{1}{4}$ (位置为 3 数值 - 位置为 2 数值)。

柱状图

- 一个变量为离散型 (Categorical)

Region	Revenue
US	720
Russian	540
South Africa	400
Canada	120
...	...






线条图



- 一个变量为数值型 – 看趋势

Days	Price
1	15.34
2	17.12
3	18.56
4	19.21
...	...




热力图


- 两个变量均为离散型，计算相关性

	Company	Country	Industry
0	A	China	Petro
1	B	US	Auto
2	C	UK	Petro
3	D	China	Auto
4	E	US	Auto



Industry	Auto	Petro
Country		
China	1.0	1.0
UK	0.0	1.0
US	2.0	0.0






Matplotlib 库

- matplotlib 是 python 最著名的绘图库，它提供了一整套和 matlab 相似的命令 API，十分适合交互式地行制图
- Matlab 的语法、python 语言、latex 的画图质量（还可以使用内嵌的 latex 引擎绘制的数学公式）
- 通过 pyplot 模块提供了一套和 MATLAB 类似的绘图 API，将众多绘图对象所构成的复杂结构隐藏在这套 API 内部，其中最重要的函数是 Plot。该函数允许你做出 2D 图形
- 引入 matplotlib 库

```
import numpy as np  
import matplotlib.pyplot as plt
```



Matplotlib 对象总览

- 在 matplotlib 中，整个图像为一个 Figure 对象。在 Figure 对象中可以包含一个，或者多个 Axes 对象（子图）。每个 Axes 对象都是一个拥有自己坐标系统的绘图区域。其逻辑关系如下



Matplotlib 对象总览 (2)

- Title 为标题。Axis 为坐标轴，Label 为坐标轴标注。Tick 为刻度线，Tick Label 为刻度注释。





基本绘图过程



- 调用 figure 创建一个绘图对象
 - `plt.figure(figsize=(8,4))`
 - `figsize`: 指定绘图对象的宽度和高度，单位为英寸
 - **`dpi`**: 指定绘图对象的分辨率，每英寸多少个像素，缺省值为 80
 - 也可以不创建绘图对象直接调用接下来的 `plot` 函数直接绘图，`matplotlib` 会为我们自动创建一个绘图对象
 - 如果需要同时绘制多幅图表的话，可以是给 `figure` 传递一个整数参数指定图表的序号








基本绘图过程



- plot 函数在当前的绘图对象中进行绘图
 - 实际上 plot() 是在 Axes(子图) 对象上绘图
 - 如果当前的 Figure 对象中没有 Axes 对象，将会为之创建一个几乎充满整个图表的 Axes 对象，并且使此 Axes 对象成为当前的 Axes 对象
- 配置对象属性
 - 通过一系列函数设置当前 Axes 对象的各个属性
- 调用 plt.savefig() 将当前的 Figure 对象保存成图像文件



matplotlib.pyplot 绘制的常见图形






画一条直线 $y=x$



```
#draw a line
fig = plt.figure()
axes = plt.axes()
x = np.linspace(0,10,21)
print(x)
y = [v for v in x]
print(y)
axes.plot(x, y)
axes.set_xlabel('x');
axes.set_ylabel('y');
axes.set_title('This is a line.')
```

```
[ 0.   0.5  1.   1.5  2.   2.5  3.   3.5  4.   4.5  5.   5.5
 6.   6.5  7.   7.5  8.   8.5  9.   9.5 10. ]
[0.0, 0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 3.5, 4.0, 4.5, 5.0, 5.5, 6.0, 6.5, 7.0,
 7.5, 8.0, 8.5, 9.0, 9.5, 10.0]
```

```
<matplotlib.text.Text at 0x9087f28>
```






画 sin 函数

```
#y = sin(x)
x = np.arange(0, 3 * np.pi, 0.1)
y = np.sin(x)
z = np.zeros(1 + int((3 * np.pi) / 0.1))
plt.plot(x, y)
plt.plot(x, z)
```

[<matplotlib.lines.Line2D at 0x90f7748>]





3、 $\sin(x)$ 、 $\sin(x^2)$


```
# draw  $\sin(x)$ ,  $\sin(x^2)$ 
x = np.linspace(0, 10, 1000)
y = np.sin(x)
z = np.cos(x**2)

plt.figure(figsize=(8,4))

plt.plot(x,y,label="$\sin(x)$",color="red",linewidth=2)
plt.plot(x,z,"b--",label="$\cos(x^2)$")

plt.xlabel("Time(s)")
plt.ylabel("Volt")
plt.title("PyPlot Example")
plt.legend()
```

<matplotlib.legend.Legend at 0x132cf28>



调整线条属性

- 线形
- 颜色
- 宽度

图例


位置 location
字体大小 font

...

https://matplotlib.org/users/legend_guide.html

```
#different lines
t = np.linspace(0, 1, 21)
# red dashes, blue line, and green triangles
plt.plot(t, t, 'r--', label="$y=x$")
plt.plot(t, t**2, 'b-s', label="$y=x^2$")
plt.plot(t, t**3, 'g-*', label="$y=x^3$")
plt.plot(t, t**4, 'k-', linewidth=5, label="$y=x^4$")
plt.legend(loc='best')
```

<matplotlib.legend.Legend at 0x144b668>




散点图

- 使用 `plot()` 绘图时，如果指定样式参数为仅绘制数据点，那么所绘制的就是一幅散列图
 - 方法所绘制的点无法单独指定颜色和大小
- **`scatter()`** 所绘制的散列图却可以指定每个点的颜色和大小

```
N = 50
x = np.random.rand(N)
y = np.random.rand(N)
area = np.pi * (15 * np.random.rand(N))**2 # 0 to 15 point radiuses
color = 2 * np.pi * np.random.rand(N)
plt.scatter(x, y, s=area, c=color, alpha=0.5, cmap=plt.cm.hsv)
```

<matplotlib.collections.PathCollection at 0x11e6fb00>





配置文件

- 绘制一幅图需要对许多对象的属性进行配置在绘图时，并没有逐一对这些属性进行配置，许多都直接采用了 matplotlib 的缺省配置
- matplotlib 将这些缺省配置保存在一个名为“matplotlibrc”的配置文件中，通过修改配置文件，我们可以修改图表的缺省样式。
- 配置文件的读入可以使用 rc_params()，它返回一个配置字典
- 在 matplotlib 模块载入时会调用 rc_params()，并把得到的配置字典保存到 rcParams 变量中
 - 可以直接修改此字典中的配置：`matplotlib.rcParams["lines.marker"] = "o"`
 - 为了方便对配置字典进行设置，可以使用 rc()
 - `matplotlib.rc("lines", marker="x", linewidth=2, color="red")`



Seaborn 库



- 针对表格数据的良好可视化工具
 - Seaborn 能够较好地支持 Groupby 功能
- Seaborn 的典型用法


```
sns.someplot(x='...', y='...', data=...)
```



使用 Seaborn 绘制 barplot

```
sns.barplot(x='sex', y='survived',  
data=ti)
```

	survived	class	sex	age	fare
0	0	Third	male	22.0	7.25
1	1	First	female	38.0	71.28
2	1	Third	female	26.0	7.92
...	...	...	...	...	...
888	0	Third	female	NaN	23.45
889	1	First	male	26.0	30.00
890	0	Third	male	32.0	7.75





使用 Seaborn 绘制 Implot

```
sns.lmplot(x="total_bill", y="tip",  
           col="day", hue="day", data=tips)
```





提纲



探索数据分析 - 可视化

- 1. 探索式数据分析
- 2. 数据可视化
- 3. 复习：数据探索的基本操作
- 4. 课堂练习与研讨



数据选取操作 - 选择与切片 (1) []



- `df['Team']` # 选取一列，成一个 **series**
- `df['Team'][0]` # 选取单例单行
- `df[['Team']]` # 选取一列，成为一个 **dataframe**
- `df[['Team','Loss']]` # 选取多列，多列名字要放在 list 里
- `df[0:]` # 第 0 行及之后的行，相当于 df 的全部数据，注意冒号是必须的
- `df[:2]` # 第 2 行之前的数据（不含第 2 行）
- `df[0:1]` # 第 0 行
- `df[1:3]` # 第 1 行到第 2 行（不含第 3 行）
- `df[-1:]` # 最后一行
- `df[-3:-1]` # 倒数第 3 行到倒数第 1 行



数据选取操作 - 选择与切片 (2) loc



- `df.loc[index, column_name]`, 根据标签选择指定的数据
 - `df.loc[0,'Team']` # 'Snow'
 - `df.loc[0:2, ['name','age']]` # 选取第 0 行到第 2 行 (含第 2 行) , name 列和 age 列的数据
 - `df.loc[[2,3],['name','age']]` # 选取指定的第 2 行和第 3 行 , name 和 age 列的数据
 - `df.loc[df['gender']=='M','name']` # 选取 gender 列是 M , name 列的数据
 - `df.loc[df['gender']=='M',['name','age']]` # 选取 gender 列是 M , name 和 age 列的数据
- loc[0:1] 和 loc[0,1] 的区别



数据选取操作 - 选择与切片 (3) `iloc`

- `iloc` 是基于位置索引的，也就是常说的几行几列
- `iloc` 完全用数字来定位 `iloc[row_index, column_index]`
 - `df.iloc[0,0]` # 第 0 行第 0 列的数据
 - `df.iloc[1,2]` # 第 1 行第 2 列的数据，32
 - `df.iloc[[1,3],0:2]` # 第 1 行和第 3 行，从第 0 列到第 2 列（不包含第 2 列）的数据
 - `df.iloc[1:3,[1,2]]` # 第 1 行到第 3 行（不包含第 3 行），第 1 列和第 2 列数据

数据选取操作 - 条件过滤

- 使用条件过滤，获取部分行数据

```
print ("提取win大于16的数据")  
print (nba_df[nba_df.Win>16])  
print ("提取某些球队的数据")  
print (nba_df[nba_df.Team.isin(['Utah Jazz'])])
```

提取win大于16的数据



	Team	Win	Loss
2	San Antonio Spurs	19	8
0	Houston Rockets	20	4
1	Golden State Warriors	21	6

提取某些球队的数据

	Team	Win	Loss
7	Utah Jazz	13	14

数据聚合操作 -groupby

- 通常我们希望对在某些属性上取值相同的数据点进行聚合分析
 - 每个政党在美国所有选举中的平均投票份额是多少？
 - 中国人民大学每个学期每个系的平均班级人数是多少？
- groupby 是解决这类问题的一个非常强大的工具。





数据聚合操作 -groupby

The **groupby** method aggregates all rows with the same value for one or more columns into a single row

```
df.groupby(  
    ['nationality', 'degree']  
) .agg(  
    mean_salary = ('salary', 'mean'),  
    min_age = ('age', 'min'),  
    max_age = ('age', 'max')  
) .reset_index()
```

Group by these column

Renamed output columns


Operation on columns

Selected columns



数据透视操作 - pivot_table

- 数据透视表是一种常见于电子表格和数据分析软件中的数据汇总工具。
- 数据透视表通过一个或多个键聚合数据表，将数据排列在一个矩形中，其中一些组键沿着行，一些沿着列。





提纲



探索数据分析 - 可视化

1. 探索式数据分析
2. 数据可视化
3. 复习：数据探索的基本操作
4. 课堂练习与研讨



表格数据可视化的基本流程


- 第一步：使用 seaborn 库进行可视化
 - 尽可能地达到预期的效果
- 第二步：使用 matplotlib 库进行调优
 - 修改标题、坐标轴标签等
 - 标注特别的数据点
- 循环执行上述步骤，直到自己满意为止
 - 很多 plot 的配置和参数需要在实践中积累

通过具体的例子熟悉可视化方法

- 案例：全世界各国的温室气体排放数据

```
co2 = pd.read_csv('../Datasets/co2-data/owid-co2-data.csv')
co2
```

	iso_code	country	year	co2	consumption_co2	co2_growth_prct	co2_growth_abs	trad
0	AFG	Afghanistan	1949	0.015	NaN	NaN	NaN	
1	AFG	Afghanistan	1950	0.084	NaN	475.00	0.070	
2	AFG	Afghanistan	1951	0.092	NaN	8.70	0.007	
3	AFG	Afghanistan	1952	0.092	NaN	0.00	0.000	
4	AFG	Afghanistan	1953	0.106	NaN	16.00	0.015	
...	...	...	...	...	...	...	...	...
25199	ZWE	Zimbabwe	2016	10.738	12.153	-12.17	-1.488	
25200	ZWE	Zimbabwe	2017	9.582	11.248	-10.77	-1.156	
25201	ZWE	Zimbabwe	2018	11.854	13.163	23.72	2.273	
25202	ZWE	Zimbabwe	2019	10.949	12.422	-7.64	-0.905	
25203	ZWE	Zimbabwe	2020	10.531	NaN	-3.82	-0.418	





【谁该为气候变化买单？-- 谁应该解决它？】

https://www.bilibili.com/video/BV1DP411z7g5/?share_source=copy_web&vd_source=61162fa3cae46557c8656dee5b330347


直方图

- 写代码绘制出 2018 年全球各国 `co2_growth_prct` 排放量的直方图
 - 提示：histplot 函数



密度分布图

- 写代码绘制出 2018 年全球各国 `co2_growth_prct` 排放量的分布图
 - 提示：`distplot` 函数




思考：密度分布图的
纵坐标与直方图的纵
坐标有何不同？



散点图



- 写代码绘制出 2018 年全球各国 gdp 和 co2 的散点图
 - 提示：scatterplot 函数







条形图





- 写代码绘制出 2018 年 co2 和 co2_per_capita 前 15 名的国家
 - 提示：barplot 函数



线条图

- 绘制中国、美国、印度、俄罗斯、日本逐年的 co2 和 co2_per_capita


图二：lineplot 函数





Lmplot 图

- 绘制中国、美国、印度、俄罗斯、日本每年的 co_2 和 $co_2_per_capita$






箱型图



- 写代码绘制出 2018-2020 年全球国家 `co2_growth_prct` 的分布
 - 提示： `boxplot` 函数





课堂练习

- 加州大学伯克利分校 (UC Berkeley) 的入学申请是否存在性别歧

```
df = pd.read_excel('./admission.xlsx')  
df
```

	ID	Gender	College	Admitted
0	1	M	A	1
1	2	M	A	1
2	3	M	A	1
3	4	M	A	1
4	5	M	A	1
...	...	...	...	...
450	451	F	F	0
451	452	F	F	0
452	453	F	F	0
453	454	F	F	0
454	455	F	F	0

455 rows x 4 columns

- 根据提供的数据 (如左图) , 完成以下练习
 - 请女生利用数据论证入学申请存在歧视女生的问题 ; 请男生说明不存在歧视女生的问题
 - 请尽可能通过多种方式说明观点 , 但每种方式只允许写一行 **Python** 代码
 - 利用 seaborn 绘制图表
 - 利用 groupby 进行分组展示
 - 利用 pivot_table 进行分组展示
 - 提示 : “辛普森悖论”

总结：数据探索分析与可视化

