

第 6 讲：数据建模与回归分析（上）


“数据科学导论”专业核心课



范举教授

fanj@ruc.edu.cn

探索数据分析：迭代工作流



技术挑战

数据的
多样性

数据的
海量性

结果的
及时性

数据的
隐私保护

.....

考虑一个案例


- 谁会赢得美国大选，希拉里还是特朗普？
 - 选前民调：希拉里支持率 52%、特朗普支持率 48%
 - 假设：所有选民在最终投票时不改变主意



~~YES!~~




回顾之前的案例



- 假设选前随机找了 1000 人进行民调
- 如果具备统计思维
 - 要考虑的总体是所有在当天投票的人
 - 这 1000 人是我抽取出的样本 (Sample)
 - 通过样本估计出的支持率存在误差：
 - 希拉里：52% $\pm$ 3%
 - 特朗普：48% $\pm$ 2%
- 结论：特朗普也有胜算！

数据建模

- 定义：模型是对现实世界的一种“有用”的简化
 - = Model is a useful simplification of reality
- 例子：重力公式
 - $G = mg, g = 9.81$
- 上述模型简化了以下因素：
 - = 不同地区的重力差异
 - = 空气阻力
 - = 等等



Essentially, all models are wrong, but some are **useful**.

-- George Box (1919 - 2013)



建立模型的三个步骤



- **Step 1 - 选择某种模型**
 - 常数模型 - Constant Model
 - 线性回归模型 - Linear Regression Model
 - 更复杂的模型
- **Step 2 - 选择目标函数**
 - 均方误差 (mean square error, MSE)
 - 平均绝对误差 (mean absolute error, MAE)
 - 其它目标函数
- **Step 3- 拟合模型 (**model fitting**) : 优化目标函数**
 - 最小化 / 最大化目标函数



提纲




数据建模与回归分析

- 1. 数据建模与参数估计
- 2. 线性回归模型：简单线性回归
- 3. 线性回归模型：多元线性回归
- 4. 梯度下降 (Gradient Descent)

我们先考虑一个最简单的模型

- 预测任务：构建模型预测某个数值型变量的取值
 - 预测《数据科学导论》课程学生的 GPA
 - 预测北京春天的空气指数
 - 预测在餐厅给服务员多少小费（餐费的百分之几）



- 左图：244 单小费的分布图
- 常数模型：忽略其他因素，使用一个数值进行预测
 - 15% 似乎比 25% 更好
 - 15% 比 14% 更好吗？
- 我们应该如何确定最优的数值？




课堂练习



- 导入 tips.csv 中的数据，并绘制小费百分比的分布图
- 本讲与相关数学课的一个区别：**数据与相关结论都要可视化出来！**

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4
...	...	...	...	...	...	...	...
239	29.03	5.92	Male	No	Sat	Dinner	3
240	27.18	2.00	Female	Yes	Sat	Dinner	2
241	22.67	2.00	Male	Yes	Sat	Dinner	2
242	17.82	1.75	Male	No	Sat	Dinner	2
243	18.78	3.00	Female	No	Thur	Dinner	2

244 rows × 7 columns





符号定义

符号		符号含义	
符号	符号含义	符号	符号含义
y	真实的数据值（如小费） - 第i项数据值表示为y_i - 数据集表示为$\{y_1, y_2, \dots, y_n\}$	y	真实的数据值（如小费） - 第i项数据值表示为y_i - 数据集表示为$\{y_1, y_2, \dots, y_n\}$
$\hat{y}$	预测的数据值（如预测的小费） 第i项数据的预测值表示为$\hat{y}_i$	$\hat{y}$	预测的数据值（如预测的小费） 第i项数据的预测值表示为$\hat{y}_i$
θ	模型的参数（Parameter） 如“真实”的小费，反映了总体的特征	θ	模型的参数（Parameter） 如“真实”的小费，反映了总体的特征
$\hat{\theta}$	模型的拟合参数（fitted parameters） 我们需要求解的目标！	$\hat{\theta}$	模型的拟合参数（fitted parameters） 我们需要求解的目标！
符号	符号含义	符号	符号含义
y	真实的数据值（如小费） - 第i项数据值表示为y_i - 数据集表示为$\{y_1, y_2, \dots, y_n\}$	y	真实的数据值（如小费） - 第i项数据值表示为y_i - 数据集表示为$\{y_1, y_2, \dots, y_n\}$
$\hat{y}$	预测的数据值（如预测的小费） 第i项数据的预测值表示为$\hat{y}_i$	$\hat{y}$	预测的数据值（如预测的小费） 第i项数据的预测值表示为$\hat{y}_i$
θ	模型的参数（Parameter） 如“真实”的小费，反映了总体的特征	θ	模型的参数（Parameter） 如“真实”的小费，反映了总体的特征
$\hat{\theta}$	模型的拟合参数（fitted parameters） 我们需要求解的目标！	$\hat{\theta}$	模型的拟合参数（fitted parameters） 我们需要求解的目标！
符号	符号含义	模型的参数（Parameter） - 如“真实”的小费，反映了总体的特征 模型的拟合参数（fitted parameters） - 我们需要求解的目标！	
y	真实的数据值（如小费） - 第i项数据值表示为y_i - 数据集表示为$\{y_1, y_2, \dots, y_n\}$		
$\hat{y}$	预测的数据值（如预测的小费） 第i项数据的预测值表示为$\hat{y}_i$		
θ	模型的参数（Parameter） 如“真实”的小费，反映了总体的特征		
$\hat{\theta}$	模型的拟合参数（fitted parameters） 我们需要求解的目标！		
符号	符号含义		
y	真实的数据值（如小费） - 第i项数据值表示为y_i - 数据集表示为$\{y_1, y_2, \dots, y_n\}$		
$\hat{y}$	预测的数据值（如预测的小费） 第i项数据的预测值表示为$\hat{y}_i$		
θ	模型的参数（Parameter） 如“真实”的小费，反映了总体的特征		
$\hat{\theta}$	模型的拟合参数（fitted parameters） 我们需要求解的目标！		

常数模型

- 我们将常数模型表示为：

$$\hat{y} = \theta$$

- 几个基本概念：

- 参数 θ ：我们使用参数来定义模型，用来描述输入数据与输出数据之间的关系。注：一些模型不含有参数（nonparametric）

- 我们的常数模型忽略了输入数据 x

- 我们后面会学习更多的模型：

- 线性回归模型： $\hat{y} = \theta_0 + \theta_1 \cdot x$

- 逻辑回归模型： $\hat{y} = \frac{1}{1 + e^{-(x^T \theta)}}$

- 模型求解目标：找到最优的参数值，表示为
- 模型求解目标：找到最优的参数值，表示为 $\hat{\theta}$

概念辨析

- 请说出以下两个概念的区别和联系

= 估计 Estimation

= 预测 Prediction



- 估计 (Estimation) 是使用观测到的样本数据来拟合参数

$$\hat{\theta} = f_1(y, x)$$

- 预测 (Prediction) 是使用拟合的参数来求解未知的数据

$$\hat{y}_i = f_2(\hat{\theta}, x_i)$$

思考：应该如何使用观测数据来估计参数？

建立模型的三个步骤


- **Step 1 - 选择某种模型**
 - 常数模型 - Constant Model
 - 线性回归模型 - Linear Regression Model
 - 更复杂的模型
- **Step 2 - 选择目标函数**
 - 均方误差 (mean square error, MSE)
 - 平均绝对误差 (mean absolute error, MAE)
 - 其它目标函数
- **Step 3- 拟合模型 (model fitting) : 优化目标函数**
 - 最小化 / 最大化目标函数

损失函数

- 损失函数 (Loss Function)

= 度量模型预测的优劣，即真实值与预测值之间的差异

= 针对我们的常数模型，度量参数与真实观测值之间的误差



以下两个估计值，哪个更好？

A. $\theta = 10$

B. $\theta = 15$

损失函数

- 损失函数 (**Loss Function**)

- = 度量模型预测的优劣, 即真实值与预测值之间的差异
- = 针对我们的常数模型, 度量参数与真实观测值之间的误差

- 平方损失 (**Squared Loss**), 也称为2损失

$$L_2(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$$

- 绝对损失 (**Absolute Loss**), 也称为1损失

$$L_1(y_i, \hat{y}_i) = |y_i - \hat{y}_i|$$

损失函数与经验风险

- 给定某个数据集，我们可以度量平均损失，也称经验风险（Empirical Risk）或目标函数（Objective function）

$$\frac{1}{n} \sum_{i=1}^n L(y_i, \hat{y}_i)$$

- 模型的平均损失度量了模型对于数据的拟合程度。
- 两种典型的平均损失
 - 均方误差（mean squared error, MSE）
 - 平均绝对误差（mean absolute error, MAE）
- 模型求解的目标：**最小化平均损失！**
 - 均方误差（mean squared error, MSE）
 - 平均绝对误差（mean absolute error, MAE）
- 模型求解的目标：**最小化平均损失！**

均方误差与平均绝对误差

- 均方误差：采用均方损失函数，针对所有数据点求平均

$$\text{MSE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


- 平均绝对误差：采用平均绝对损失函数，针对所有数据点求平均
- 平均绝对误差：采用平均绝对损失函数，针对所有数据点求平均

$$\text{MAE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$




课堂练习

- 给定五个数据点 $[20, 22, 24, 26, 25]$ 计算的不同估计值 θ 的平方误差均方误差





考虑 Tips 数据集



- 通过左图的观察，你能发现什么？

建立模型的三个步骤

- **Step 1 - 选择某种模型**
 - 常数模型 - Constant Model
 - 线性回归模型 - Linear Regression Model
 - 更复杂的模型
- **Step 2 - 选择目标函数**
 - 均方误差 (mean square error, MSE)
 - 平均绝对误差 (mean absolute error, MAE)
 - 其它目标函数
- **Step 3- 拟合模型 (model fitting) : 优化目标函数**
 - 最小化 / 最大化目标函数

常数模型与均方误差

- 平均损失通常表示为参数的函数例如：

$$R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \theta)^2$$

- 思考：如何求解最小化平均损失时参数的取值

- 思考：如何求解最小化平均损失时参数 θ 的取值

$$\text{例子：给定五个数据点 } \hat{a} = [20, 21, 22, 29, 33], \text{ 请根据上式求解 } \theta$$

- 例子：给定五个数据点 $[20, 21, 22, 29, 33]$ ，请根据上式求解 $\hat{\theta}$





请计算下表示单元格的分值

A. 22 B. 25 C. 24 D. 27

常数模型与均方误差

- 例子：给定五个数据点[20,21,22,29,33]，求解 $\hat{\theta}$



求解过程

- 均方误差：

- 针对参数求导 $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \theta)^2$

- 针对参数 θ 求导：

- 令一阶导数等于 0，得到 $\frac{d}{d\theta} R(\theta) = \frac{1}{n} \sum_{i=1}^n \frac{d}{d\theta} (y_i - \theta)^2 = \frac{-2}{n} \sum_{i=1}^n (y_i - \theta)$

- 令一阶导数等于 0，得到

- 课堂练习：1. 请计算二阶导数；2. 请计算时的取值

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (y_i - \theta) &= 0 \\ \Rightarrow \hat{\theta} &= \frac{\sum_{i=1}^n y_i}{n} = \mathbf{mean}(y) \end{aligned}$$

- 课堂练习：1. 请计算二阶导数；2. 请计算 $\hat{\theta} = \mathbf{mean}(y)$ 时 $R(\theta)$ 的取值

常数模型与均方误差

- 当 $\theta = \text{mean}(y)$ 时，可以求得：

$$R(\hat{\theta}) = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \sigma^2$$

- 几个结论：

- 给定常数模型和均方误差，最优的参数估计是观测数据的均值
- 几个结论：
 - 一 给定均值作为估计，此时均方误差达到最小，等于观测数据的方差
 - 二 给定常数模型和均方误差，最优的参数估计是观测数据的均值
 - 三 上述结论解释了为什么均值是重要的统计变量
- 注意：
 - 一 给定均值作为估计，此时均方误差达到最小，等于观测数据的方差
 - 二 上述结论解释了为什么均值是重要的统计变量
 - 三 上述结论成立的条件：① 模型为常数；② 损失函数采用均方损失
- 注意：
 - 一 上述结论成立的条件：① 模型为常数；② 损失函数采用均方损失

常数模型与平均绝对误差

- 平均损失通常表示为参数的函数例如：

$$R(\theta) = \frac{1}{n} \sum_{i=1}^n |y_i - \theta|$$

- 思考：如何求解最小化平均损失时参数的取值
- 思考：如何求解最小化平均损失时参数 θ 的取值

- 例子：给定五个数据点，请根据上式求解 θ

- 例子：给定五个数据点[20,21,22,29,33]，请根据上式求解 $\hat{\theta}$





请从以下候选中做出选择

A. 22 B. 25 C. 24 D. 27


常数模型与平均绝对误差

- 例子：给定五个数据点 $[20, 21, 22, 29, 33]$ ，求解 $\hat{\theta}$



常数模型与平均绝对误差

- 例子：给定五个数据点[20,22,29,33]，求解 $\hat{\theta}$




求解过程

- 思考：求解的关键是如何计算的导数

- 提示：将绝对值写成以下分段函数

$$|y_i - \theta| = \begin{cases} y_i - \theta & \text{if } \theta \leq y_i \\ \theta - y_i & \text{if } \theta > y_i \end{cases}$$

- 同样地，可以将平均绝对损失针对的导数写为



- 同样地，可以将平均绝对损失针对 θ 的导数写为分段函数

— 注：时不可导。此处为了简便，忽略该点

$$\frac{d}{d\theta} |y_i - \theta| = \begin{cases} -1 & \text{if } \theta < y_i \\ 1 & \text{if } \theta > y_i \end{cases}$$

— 注： $\theta = y_i$ 时不可导。此处为了简便，忽略该点

求解过程

- 平均绝对误差：

- 平均绝对误差： $R(\theta) = \frac{1}{n} \sum_{i=1}^n |y_i - \theta|$

- 针对参数 θ 求导：

- 令一阶导数等于0，得到

$$\frac{d}{d\theta} R(\theta) = \frac{1}{n} \sum_{i=1}^n \frac{d}{d\theta} |y_i - \theta| = \frac{1}{n} \left[\sum_{\theta < y_i} (-1) + \sum_{\theta > y_i} 1 \right]$$

- 令一阶导数等于0，得到

- 思考：根据上述公式估计值应该取多少？

$$\frac{1}{n} \left[\sum_{\theta < y_i} (-1) + \sum_{\theta > y_i} 1 \right] = 0$$

$$\Rightarrow \sum_{\theta < y_i} 1 = \sum_{\theta > y_i} 1$$

- 思考：根据上述公式估计值 $\hat{\theta}$ 应该取多少？

常数模型与平均绝对误差

- 根据之前推导，可以求得： $\hat{\theta}$ 此时有 $\text{median}(y)$ ，此时有：

$$R(\hat{\theta}) = \frac{1}{n} \sum_{i=1}^n |y_i - \text{median}(y)|$$

平均绝对离差
Mean Absolute Deviation


- 几个结论：
- 几个结论：
 - 给定常数模型和平均绝对误差，最优参数估计是观测数据中位数
 - 给中位数作为估计，平均绝对误差达到最小
 - 给定常数模型和平均绝对误差，最优参数估计是观测数据中位数
 - 此时的参数估计不容易受到离群点 (Outlier) 的影响
 - 给中位数作为估计，平均绝对误差达到最小
 - 此时的参数估计不容易受到离群点 (Outlier) 的影响

常数模型与平均绝对误差

• 思考：



- = 如果观测数据变为[20, 21, 22, 29, 33, 35]
- = 此时的估计值应为多少？

- 答案：不唯一，区间[22, 29]内任意的取值均可。你能证明吗？



Recap : 对比 MSE 和 MAE

- 考虑简单数据集 $[20, 22, 22, 22, 23]$ 和常数模型



- MSE 的平均损失曲线光滑；MAE 的平均损失曲线不光滑
 - 选择 MSE；估计值 $\hat{\theta} = \bar{y}$ — 大多数模型选择 MSE
 - 选择 MAE；估计值 $\hat{\theta} = \text{median}(y)$ (可能不唯一)




思考：MSE 的局限性

- 考虑简单数据集 $[10, 11, 12, 20, 200]$ 为异常值 200 清洗前随机函数计算随机函数为 MSE 的系数估计的参数的损失及相应的损失 Loss 值
- 进一步思考：你能从上述结果中得到什么结论
- 再进一步思考：如果让你设计一个新的损失函数可以对数据中的异常值更加鲁棒 (Robust Learning)，你会怎么设计？



Huber Loss Function

$$L_{\alpha}(\theta, \mathbf{y}) = \frac{1}{n} \sum_{i=1}^n \begin{cases} \frac{1}{2}(y_i - \theta)^2 & |y_i - \theta| \leq \alpha \\ \alpha(|y_i - \theta| - \frac{1}{2}\alpha) & \text{otherwise} \end{cases}$$



思考 :: 在Huber Loss中, 参数增大或减小对上述曲线有何影响?

Recap: 几个重要概念

- 下面几个概念后面会反复出现 !!
 - = 观测值 x_i 与预测值 $\hat{y}_i$
 - = 参数 θ 与拟合参数 (或参数估计值) $\hat{\theta}$
 - = 估计 (Estimation) 与预测 (Prediction)
 - = 损失函数与平均损失 (经验风险)
 - = 均方误差 MSE 与平均绝对误差 MAE
 - = 参数求解 $\Rightarrow$ 平均损失 (经验风险) 最小化 !



提纲



数据建模与回归分析

1. 数据建模与参数估计
2. 线性回归模型：简单线性回归
3. 线性回归模型：多元线性回归
4. 梯度下降 (Gradient Descent)

Simple Linear Regression (SLR)

- 让我们把模型变得更复杂一些

= 考虑输入变量 x

$$\hat{y}_i = \theta_0 + \theta_1 x_i$$

- 为了表示方便，我们将上式写成


$$\hat{y}_i = a + bx_i$$

- 该模型称为简单线性回归模型，简称 SLR 模型。

= 例如：右图建立房间数量与房屋价格之间的 SLR 模型。



```
# Between prices and No. of rooms
sns.regplot(x="RM", y="PRICE", data=boston_df, fit_reg=True)
plt.title("Relationship between No. of rooms and Price")
plt.show()
```

Relationship between No. of rooms and Price



Simple Linear Regression (SLR)

- 度量变量之间的相关性 (Correlation) 是典型的回归问题
- 举例：你的身高与你父母的身高之间存在相关性吗？



弗朗西斯·高尔顿
(Francis

Galton)
1855年论文：《遗传的身高向平均数方向的回归》

SLR 模型与 MSE 目标函数

- 给定SLR模型, 均方误差MSE可以写为

$$R(a, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (a + bx_i))^2$$

- 优化任务：如何计算最优的参数组合

- 优化任务：如何计算最优的参数组合

- 数学工具：

- 计算变量的(一阶偏导)令一阶偏导为0, 从而求解

$$\frac{\partial R(a, b)}{\partial a} = 0, \frac{\partial R(a, b)}{\partial b} = 0$$

- 数学工具：

- 计算变量 (a, b) 的一阶偏导, 令一阶偏导为0, 从而求解 $(\hat{a}, \hat{b})$

求解过程 - 1

- 计算目标函数对(变量)的变量偏得一阶偏导

- 令一阶偏导等于 0 $\frac{\partial R(a,b)}{\partial a} = \frac{-2}{n} \sum_{i=1}^n (y_i - bx_i - a)$

- 令一阶偏导等于0，得到

$$\begin{aligned} & \frac{-2}{n} \sum_{i=1}^n (y_i - bx_i - a) = 0 \\ & , \text{其中和分别和的均值} \\ \Rightarrow & \sum_{i=1}^n y_i - b \sum_{i=1}^n x_i - a \cdot n = 0 \end{aligned}$$

$$\Rightarrow \hat{a} = \bar{y} - b\bar{x}, \text{其中}\bar{y}\text{和}\bar{x}\text{分别}y\text{和}x\text{的均值}$$

求解过程 - 2

- 将估计值 $a = \bar{y} - b\bar{x}$ 代入目标函数，求得

$$R(a, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (\bar{y} - b\bar{x} + bx_i))^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y} - b(x_i - \bar{x}))^2$$

- 计算目标函数对变量的一阶偏导

- 计算目标函数 $R(a, b)$ 对变量 b 的一阶偏导

$$\frac{\partial R(a, b)}{\partial b} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y} - b(x_i - \bar{x}))$$

- 令一阶偏导等于0，得到

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) - b \sum_{i=1}^n (x_i - \bar{x})^2 = 0$$

$$\Rightarrow \hat{b} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

求解过程 - 3

- 我们使用统计量对上述公式进行替换，得到

$$\sigma_x^2 = \sum_{i=1}^n (x_i - \bar{x})^2$$


$$r \cdot \sigma_x \sigma_y = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- 其中：为统计学经常使用的皮尔森相关系数
- 因此，我们得到参数估计
- 其中：r为统计学经常使用的皮尔森相关系数
- 因此，我们得到参数估计

$$\hat{b} = r \frac{\sigma_y}{\sigma_x} ; \hat{a} = \bar{y} - \hat{b}\bar{x}$$




高尔顿数据的回归结果






损失函数的可视化




变量之间的相关性


- 思考并回答下面变量之间的相关性




完全随机



强线性相关



非线性相关







线性相关

皮尔森相关系数

- 背景：卡尔·皮尔森是高尔顿的学生
- 皮尔森相关系数

$$r = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma_x} \right) \left(\frac{y_i - \bar{y}}{\sigma_y} \right) = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sigma_x \sigma_y}$$



使用 Python 完成课堂练习

- 给定一组训练数据
 - $(2, 4)$
 - $(5, 1)$
 - $(8, 9)$
- Q1: 请计算一个简单线性回归模型的最优参数的最优参数
 - $\hat{a} = ?$
 - $\hat{b} = ?$
- Q2: 请绘制散点图和拟合的曲线
- Q2: 请绘制散点图和拟合的曲线
- Q3: 请绘制损失函数的示意图
- Q3: 请绘制损失函数的示意图



如何评判回归模型的优劣

- 基本想法 :: 度量观测值与预测值之间的差异
- 均方根误差 (Root Mean Squared Error)

$$\text{RMSE}(y, \hat{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- 均方根误差 RMSE 是 MSE 损失函数的平方根
- 均方根误差 RMSE 与观测值与预测值的量纲相同
- 均方根误差 RMSE 是 MSE 损失函数的平方根
- 均方根误差 RMSE 越小，说明模型越准确
- 均方根误差 RMSE 与观测值 y 与预测值 $\hat{y}$ 的量纲相同
- 均方根误差 RMSE 越小，说明模型越准确

均方根误差

- 课堂编程练习：
 - 请在 notebook 中编写 rmse 函数计算均方根误差

```
def rmse(y, yhat):  
    # Write down your code here  
    return 0
```

- 请计算以下两个模型的均方根误差，并比较大小

$$PRICE = -34.67 + 9.1 * RM$$

$$PRICE = -11.36 + 5.09 * RM + (-0.64) * LSTAT$$

拟合优度 (Multiple R^2)

- 拟合优度 (Multiple R^2) 度量预测值对观测值的拟合程度
- 拟合优度 R^2 定义与皮尔森相关系数的平方

$$R^2 = [r(y, \hat{y})]^2$$

- 拟合优度的取值范围在 $[0, 1]$, 越高说明模型准确性越好
- 拟合优度的含义 :: 模型在多大程度上解释了观测值的变化
- 针对包含截距的线性回归模型, 拟合优度也可如下计算

$$R^2 = \frac{\text{variance of fitted values}}{\text{variance of true values}} = \frac{\sigma_{\hat{y}}^2}{\sigma_y^2}$$

拟合优度 (Multiple R^2)

- 课堂编程练习：
 - 请在 notebook 中编写 multiple-r-squared 函数计算拟合优度

```
def MultipleRSquared(y, yhat):  
    # Write down your code here  
    return 0
```

- 请计算以下两个模型的拟合优度, 并比较大小

$$PRICE = -34.67 + 0.1 * RM$$

$$PRICE = -11.36 + 5.09 * RM + (-0.64) * LSTAT$$