

第 8 讲：分类问题与典型分类模型

“数据科学导论”专业核心课



范举 教授

fanj@ruc.edu.cn

典型的机器学习问题

- 分类 (Classification) 问题
 - 预测类别，如数字、是 / 否为垃圾邮件




Is This A or B
(or C, D, ...)?


- 这张照片中是猫还是狗？
- 这条评论体现了积极还是消极情绪？
- 这个用户是否会点击给他推送的广告？



典型的机器学习问题



- 回归 (Regression) 问题
 - 估计回归的参数，如权重




How much or How Many?

- 本周的股票价格如何变化？
- 下礼拜一的气温会是多少？
- 中国第一季度的 GDP 增长会是多少？

典型的机器学习问题

- 聚类 (clustering) 问题



- 目标用户群体分类
- 文档主题划分
- 样本群组分析
- 异常检测

How Is This Organized?



MH370

Web Images Videos Dict Knows News Maps Explore

Any time ~ Best match ~ 251,000 RESULTS

MH370之谜新证据？留尼汪岛现西马来矿泉水瓶-中国药膏
克雷斯在社交网站上公布疑似MH370之谜新证据：三个矿泉水瓶和一个中国制造药膏。（图片来源：澳大利亚新闻网） 据澳大利亚新闻网4日报道，继上周在留尼汪岛发现波音777的机翼残骸后 ...
中国台湾网 · 4 minutes ago


毛里求斯开始搜寻马航MH370
【导语】：8月3日，马来西亚代表团与法方相关人员在巴黎举行闭门会议，讨论对在法属留尼汪岛发现的飞机襟副翼残骸进行鉴定事宜。同时印度洋西南部岛国毛里求斯宣布，毛里求斯警方将在沿海地区寻找可能出现的马航MH370客机残骸。
湖南政协新闻网 · 10 minutes ago

毛里求斯警方开始寻找马航MH370客机疑似残骸 人民网上海频道
法马两国警方已确认残骸鉴定 毛里求斯警方搜寻MH370 齐鲁晚报
In-depth coverage

大马法国专家会晤 谈MH370疑似残骸鉴定事宜
中新网8月4日电 据外媒报道，当地时间3日，马来西亚调查人员在巴黎与法国官员举行了会晤，讨论马航MH370客机疑似残骸的鉴定事宜。马来西亚民航局局长阿扎鲁丁·拉赫曼在会后的声明中表示，马来西亚与法国理解乘客家属关切和焦虑的心情 ...
网易新闻 · 5 minutes ago

马来交通部长：飞机残骸是否来自MH370有待证实
资料图：当地时间2015年7月31日，法国兵兵运发现的襟副翼。 原标题：马交通部长：飞机残骸是否来自MH370仍有待证实 中新社吉隆坡8月3日电(记者赵胜玉)马来西亚交通部长廖中莱3日表示 ...
每日甘肅网 · 1 hour ago

马来官方：疑似MH370残骸确属波音777客机 中国经济网
马方确认残骸属波音777 还不确定是否是MH370残骸 滨州传媒网
In-depth coverage



提纲



分类问题与典型分类模型

- 1. 分类问题与监督学习
- 2. 逻辑回归模型
- 3. 感知机模型
- 4. 决策树模型

分类问题与监督学习

- 学习目标

- $f : X \rightarrow Y$

- 训练数据

- $\{(x_i, y_i) \in X \times Y\}$

- 学习 (训练) 过程

- 学习寻找训练 f 过程


- 满足 $y_i \approx \hat{f}(x_i)$

- 预测 (测试) 过程


- 预测给定新数据过程

- 输入 x

- 输出



案例：手写数字识别



图片像素 28×28


□ 请问你如将一张照片表示成一个“点”？

- 输入数据
 - 将图片数据表示为一个向量 $x \in \mathbb{R}^{784}$
- 输出模型
 - 学习出分类器对图片进行分类
 - $f: \mathbb{R}^{784} \rightarrow \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$

- A.** 考虑图片文件的格式与大小
- B.** 考虑图片中的像素点

案例：手写数字识别

- 建模成监督学习中的分类问题（ Supervised Classification ）
- 基于训练数据集进行学习，如每个数字 6000 张图片



- 可以在测试集上达到分类误差 0.4%
 - 第一个被广泛应用的机器学习系统：邮编的识别与校验

案例二：微信朋友圈广告互动行为预测

- 什么是分类问题？
 - 利用**训练集**学习出某个**函数**，用来预测某些**未知的类别型变量**
- 业界的真实示例：微信朋友圈广告互动行为预测
 - 广告互动：微信朋友圈广告具有互动属性
 - 品牌随着关系链传播，好友的互动加强传播效果



广告互动

点赞

评论

@ 好友



请将上述问题建模成
 $y = f(x)$
形式



案例二：微信朋友圈广告互动行为预测

- 什么是分类问题？
 - 利用**训练集**学习出某个**函数**，用来预测某些**未知的类别型变量**
- 业界的真实示例：朋友圈广告互动行为预测






监督学习概览




- 提出问题 (Question)
- 准备数据 (Input data)
- 选择特征 (Features)
- 标注数据 (Labels)
- 学习算法 (Algorithm)
- 评价模型 (Evaluation)



分类问题的基本步骤



Question □ Data □ Features □ Algorithm □ Evaluation

- 虚假信息 (Misinformation) 检测
 - 问题定义应明确而具体



用户在社交媒体
发布的信息，如微博

训练集



案例：互联网虚假信息检测



虚假信息散布者

虚假信息内容

- 文本
 - 文字
 - 标签
 - 链接
 - 表情
- 图片
- 视频 (GIF)

虚假信息时空属性


- 日期、时间
- 地点

虚假信息传播者

- 点赞、回复
- 转发



案例：互联网虚假信息检测



- 案例分析：真实的中文虚假信息

娱乐类（标题）

曾毅退出凤凰传奇，与庞龙合唱，原来他唱功这么好！

唐嫣学生装现身机场，宽松胖大疑似怀孕？罗晋要升级当爸爸！

《七仙女》开拍，赵丽颖和郑爽谁更适合演七仙女和鹿晗搭档

今天鹿晗和关晓彤分手了吗？

佟丽娅被爆离婚，网友为何大喊：痛快人心！

社会类（标题）

家长注意了！初三有这6个现象的孩子，成绩会越来越差！

摊贩城管一家亲！10月1日起，农户进城摆摊不用愁了，可放心买卖

电瓶车用久了电池就得换？别傻了，教你1招，再多骑10年都没问题！

医院交停车费，找回来一枚硬币，价值3000元，真不敢相信！

还用别人的驾驶证代扣分？现在已经行不通了！

分类问题的基本步骤

Question → **Data** → Features → Algorithm → Evaluation


• 准备虚假信息检测的数据

• 原始数据获取

- 根据 Twitter API 获取数据

• 数据标注

- 通过人工标注，为收集到的每条 tweet 打标签：1 为虚假信息；0 为真实信息



虚假信息散布者

虚假信息内容

- 文本
 - 文字
 - 标签
 - 链接
 - 表情
- 图片
- 视频 (GIF)

虚假信息时空属性

- 日期、时间
- 地点

虚假信息传播者

- 点赞、回复
- 转发

分类问题的基本步骤

Question □ Data □ **Features** □ Algorithm □ Evaluation

- 特征提取

- 数据表示

- $\{(x_i, y_i) \in X \times Y\}$
- $x_i \in \mathbb{R}^d$

- 学习（训练）过程

- 寻找 $\hat{f} \in F$
- 满足 $y_i \approx \hat{f}(x_i)$

- 特征 / 特征向量



你如何区分
汪星人
喵星人



你觉得下面的特征是否合理？

A. 合理 **B. 不合理**



分类问题的基本步骤

Question □ Data □ **Features** □ Algorithm □ Evaluation

- 特征提取

- 数据表示

- $\{(x_i, y_i) \in X \times Y\}$
- $x_i \in \mathbb{R}^d$

- 学习（训练）过程

- 寻找 $\hat{f} \in F$
- 满足 $y_i \approx \hat{f}(x_i)$

- 特征 / 特征向量



你如何区分
汪星人
喵星人



你觉得下面的特征是否合理？

A. 合理 **B. 不合理**



分类问题的基本步骤

Question □ Data □ **Features** □ Algorithm □ Evaluation

- 特征提取

- 数据表示

- $\{(x_i, y_i) \in X \times Y\}$
- $x_i \in \mathbb{R}^d$

- 学习（训练）过程

- 寻找 $\hat{f} \in F$
- 满足 $y_i \approx \hat{f}(x_i)$


- 特征 / 特征向量



你如何区分


汪星人

喵星人





互联网应用案例：虚假信息检测



- 如何给一条 Tweet 信息提取特征？

#hurricaneharvey2017

Believe it or not, this is a shark on the freeway
in #Houston, #Texas. #HurricaneHarvy
#HarveyStorm #houstonflood



Text Feature	Example
Length of post	#words, #characters
Punctuation marks	Question mark ? Exclamation!
Emojis/Emoticons	Angry face ;-L 😡
Sentiment	Sentiment/swear/curse words
Pronoun (1 st , 2 nd , 3 rd)	I, me, myself, my, mine
URL, PageRank of domain	@AndrewGirdwood Have you heard Google was hiring people to work from home? pretty cool i thought http://dwarfurl.com/1f291
Mention (@)	
Hashtag (#)	Free President #Gbagbo #8demarzo #stopkony #SOLARSTORM #iwd #ftmedia12 #BarackObama #cnn #breakingNews #Syria #sarkozy

分类问题的基本步骤

- 案例分析：真实的中文虚假信息

娱乐类（标题）

曾毅退出凤凰传奇，与庞龙合唱，原来他唱功这么好！

唐嫣学生装现身机场，宽松胖大疑似怀孕？罗晋要升级当爸爸！

《七仙女》开拍，赵丽颖和郑爽谁更适合演七仙女和鹿晗搭档

今天鹿晗和关晓彤分手了吗？

佟丽娅被爆离婚，网友为何大喊：痛快人心！

社会类（标题）

家长注意了！初三有这 6 个现象的孩子，成绩会越来越差！

摊贩城管一家亲！10月1日起，农户进城摆摊不用愁了，可放心买卖

电瓶车用久了电池就得换？别傻了，教你 1 招，再多骑 10 年都没问题！

医院交停车费，找回来一枚硬币，价值 3000 元，真不敢相信！

还用别人的驾驶证代扣分？现在已经行不通了！





特征抽取举例
问句用感叹号出现在篇
消息中的频率

分类问题的基本步骤

Question □ Data □ **Features** □ Algorithm □ Evaluation

- 分类器需要从标注数据 (Labeled Data) 中进行学习
- 虚假信息检测最简单的特征选取策略
 - 5000张脸
 - 10⁶张非脸的图片
 - 图片进行了规范化
 - 调整尺寸
 - 变为黑白



训练集

- 正例 : 15 个
- 负例 : 15 个

备注：左图横坐标只考虑整数点

分类问题的基本步骤


Question □ Data □ Features □ **Algorithm** □ Evaluation

- 虚假信息检测最简单的分类算法
 - 设置一个阈值 C , 如 $C=1$




使用介绍的 k 近邻分类器, 如果一个样本感叹号 / 问号数量为 2 , 考虑 $k=7$, 分类结果是
A. 正例 B. 负例

数量



```
if F_i >= C:
    return 1
else:
    return -1
```




K 近邻分类器

- 算法


- 对每个测试样本 x ，在训练集中找到离 x 最近的 K 个训练样本
- 根据这 K 个样本多类别标签投票，多数标签作为 x 的预测标签

e.g. $K = 3$

• applicable to
multi-class case




$K = 1$



Voronoi diagram:


- partitions the space into regions
- boundaries are equal distance from training points



Classification boundary:

- non-linear

例子：手写数字识别





- MNIST data set
- Distance = raw pixel distance between images
- 60K training examples
- 10K testing examples
- K-NN gives 5% classification error

$$D(A, B) = \sum_{ij} \sqrt{(a_{ij} - b_{ij})^2}$$

采样假设：训练集与测试集


- 假设训练样本和测试数据是独立采样
- 训练数据与测试数据的分布很可能不一致
- 分类误差的度量 $= \frac{1}{N} \sum_{i=1}^N \underbrace{[y_i \neq f(x_i)]}_{\text{loss function}}$ The “risk”






$K = 1$

Training data



error = 0.0

Testing data




error = 0.15




$K = 3$

Training data



error = 0.0760

Testing data




error = 0.1340




$K = 7$

Training data



error = 0.1320

Testing data




error = 0.1110




K = 21

Training data



error = 0.1120


Testing data



error = 0.0920

深入理解

- 要点：
 - 监督学习旨在测试集上取得好的预测精度，而测试集在训练时是未知的
 - 在训练集上最小化损失函数来设定参数，不一定能获得最佳的分类模型
 - 我们希望模型能够有效地对核心的数据分布建模，而忽略数据中的噪音
 - 欠拟合与过拟合





参数选择与验证集



- 随着 K 增加
 - 分类边界面越来越平滑
 - 训练误差增加
- 把整个数据分成 3 部分：
 - 训练集：学习模型参数
 - 验证集：不用来学习，用来选择模型或者调节重要参数
 - 测试集：用来评估模型预测效果，通常评估效果会比验证集差一些
- K 是参数， K 的选择可以基于**验证集**
 - 把训练集进一步分为训练集和验证集
 - 通过验证集的损失误差选择 K



分类问题的基本步骤

Question □ Data □ Features □ Algorithm □ **Evaluation**

- 如何评价你分类器的优劣？
 - 能否直接在训练集评测？
 - **NO !**



预测结果

	正例	负例
标准答案		
正例	12	3
负例	3	12

Accuracy = $\frac{24}{30} = 80\%$




分类问题的基本步骤

Question □ Data □ Features □ Algorithm □ **Evaluation**

- 如何评价你分类器的优劣？
 - 划分为训练集和测试集
 - 交叉验证：K-fold cross validation

fold1	1	2	3	4	5	test accuracy1
fold2	1	2	3	4	5	test accuracy2
fold3	1	2	3	4	5	test accuracy3
fold4	1	2	3	4	5	test accuracy4
fold5	1	2	3	4	5	test accuracy5

平均



精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

预测结果

标准答案		正例	负例
	正例	8	12
	负例	8	72

Accuracy = $\frac{80}{100} = 80\%$



看指标很不错
但总感觉哪里不对

几个关键概念

- True Positive (TP): 正确识别
- False Positive (FP): 错误识别
- True Negative (TN): 正确拒绝
- False Negative (FN): 错误拒绝



将 **TP/FP/TN/FN** 填到下表

标准答案		预测结果	
		正例	负例
	正例		
	负例		

混淆矩阵
Confusion Matrix

精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

预测结果

标准答案		正例	负例
	正例	8	12
	负例	8	72

Accuracy = $\frac{80}{100} = 80\%$



看指标很不错
但总感觉哪里不对

几个关键概念

- True Positive (TP): 正确识别
- False Positive (FP): 错误识别
- True Negative (TN): 正确拒绝
- False Negative (FN): 错误拒绝



将 **TP/FP/TN/FN** 填到下表

标准答案		正例	负例
	正例	TP	FN
	负例	FP	TN

预测结果

精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

预测结果

标准答案		正例	负例
	正例	8	12
	负例	8	72

$$\text{Accuracy} = \frac{80}{100} = 80\%$$



看指标很不错
但总感觉哪里不对

- 引入新的指标

- Precision - 准确率

$$\text{Precision} = \frac{TP}{TP + FP}$$

- Recall - 召回率

$$\text{Recall} = \frac{TP}{TP + FN}$$

- F1 Score - F 值

$$F1 = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}}$$

请计算左表

精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

预测结果

标准答案		正例	负例
	正例	8	12
	负例	8	72

$$\text{Accuracy} = \frac{80}{100} = 80\%$$



看指标很不错
但总感觉哪里不对

- 引入新的指标

- Precision = 50%
- Recall = 40%
- F1 Score = 44%



实际分类效果很差！


分类问题的基本评测

Question □ Data □ Features □ Algorithm □ **Evaluation**

- 如何评价你分类器的优劣？



请计算下表单元格的分值
A. 0 B. 0.5 C. 1.0



C	Precision	Recall	F1 Score
0			
1			
2			
3			
4			


分类问题的基本评测

Question □ Data □ Features □ Algorithm □ **Evaluation**

- 如何评价你分类器的优劣？



请计算下表单元格的分值
A. 0 B. 0.5 C. 1.0




C	Precision	Recall	F1 Score
0			
1			
2			
3			
4			



分类问题的基本评测

Question □ Data □ Features □ Algorithm □ **Evaluation**

- 如何评价你分类器的优劣？



请计算下表单单元格的分值


A: $\frac{14}{15}$ B: $\frac{19}{30}$ C: $\frac{14}{19}$

C	Precision	Recall	F1 Score
0			
1			
2			
3			
4			

分类问题的基本评测

Question □ Data □ Features □ Algorithm □ **Evaluation**

- 如何评价你分类器的优劣？



请计算下表单单元格的分值

A: $\frac{14}{15}$ B: $\frac{19}{30}$ C: $\frac{14}{19}$

C	Precision	Recall	F1 Score
0			
1			
2			
3			
4			



提纲



分类问题与典型分类模型

- 1. 分类问题与监督学习
- 2. 逻辑回归模型
- 3. 感知机模型
- 4. 决策树模型



建立与评估模型的四个步骤

步骤	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)
	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	??	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	??
	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	??	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	??
	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent
	Step 4 评估模型效果	RMSE or R^2	??	Step 4 评估模型效果	RMSE or R^2	??
Step 1 选择某种模型	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	??		
	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	??			
	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	??			
	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent			
	Step 4 评估模型效果	RMSE or R^2	??			
Step 2 选择目标函数	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	??		
	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	??			
	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	??			
	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent			
	Step 4 评估模型效果	RMSE or R^2	??			
Step 3 拟合模型参数	Sklearn / Gradient Descent			Sklearn / Gradient Descent		
Step 4 评估模型效果	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	??		
	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	??			
	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	??			
	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent			
	Step 4 评估模型效果	RMSE or R^2	??			

复习：线性回归

- **预测问题**：根据若干个协变量（特征） x 预测目标变量 y
- **回归**：估计随机变量（未知分布的） $f^*(x)$
- **线性回归**：假设并估计参数向量并估计参数向量 θ^*
- **模型**：通过选择 θ 可以得到所有分布的集合。
- **拟合模型**：选择一个损失函数，然后最小化损失

$$L(\theta, X, y) = \frac{1}{n} \sum_{i=1}^n (y_i - \theta \cdot X_i)^2 + \lambda \sum_{j=1}^p |\theta_j|$$

- **思考**：分类问题能建模成类似的形式吗？



逻辑回归模型

DEMO 演示

如何类似地解决分类问题

- **思路**：目标变量感觉上是与特征相关的标称或Q/0/1 变量
 — 令(表示)表随机变量中为特征为特征目标变量

- **问题建模**：估计期望 $E(Y|X) = 1 \cdot P(Y = 1|X) + 0 \cdot P(Y = 0|X)$
 问题建模：估计期望

$$= P(Y = 1|X) = f_{\theta}^*(X)$$

- **线性分类器**：将回归问题进行**某种转化**；估计 $P(Y = 1|X)$

- **本讲重点**：

- **问题建模**：掌握如何“调整”线性回归模型，以解决分类问题
- **问题求解**：掌握如何对上述问题进行求解



逻辑回归 (Logistic Regression)

- 基本思路

- 在线性回归输出的结果上加一个非线性函数 σ
- 思考：这个函数具备什么性质？

$$f_{\theta}(x) = \sigma(\theta \cdot x)$$

线性回归

非线性函数

- 函数应满足的性质：

= 函数的输出需要在 $[0,1]$

$$\sigma(t) = \frac{1}{1 + \exp(-t)} \quad \text{sigmoid 函数}$$

= 能够定义损失函数 Let $z_i = f_{\theta}(X_i)$.

$$L(\theta, X, y) = -\frac{1}{n} \sum_{i=1}^n [y_i \log z_i + (1 - y_i) \log(1 - z_i)]$$



逻辑回归 (Logistic Regression)

- 基本思路

- 在线性回归输出的结果上加一个非线性函数 σ
- 思考：这个应用具备什么性质？

$$f_{\theta}(x) = \sigma(\theta \cdot x)$$

线性回归

非线性函数

- 如何进行预测：设定决策规则

- 例如： E.g. if $f(x) \geq 0.5$, predict 1



为什么使用 sigmoid 函数？

- 请推导以下公式：

$$\log \left(\frac{P(Y = 1|X)}{P(Y = 0|X)} \right) = \boxed{?}$$

$$f_{\theta}(x) = \sigma(\theta \cdot x)$$
$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$

- 使用 sigmoid 函数隐含的基本假设
 - 比率比 (**odds ratio**) 对数是特征的线性函数
 - 例：利用比率比对数判别“基因突变是否导致患癌症的比例更高”

		是否患有癌症	
		是	否
有无突变基因	有	23	117
	无	6	210

$$\log \left(\frac{23}{6} \right) = \log (6.88) = 1.93$$


比率比越大反映特征的预测性越好

为什么使用 sigmoid 函数？

- 参数直观上是逻辑回归模型的“斜率”

- 如果是正的，对应维度的特征越大，预测的概率越大

- 如果是负的，对应维度的特征越大，预测的概率越小



课堂练习

- 考虑一个逻辑回归模型的参数为 $\hat{\theta}$ 给定0.1个数据点给定的类别= [15,1]，请给出预测的类别



$$\hat{P}_{\theta}(Y = 1|x) = \sigma(x^T \theta)$$



建立与评估模型的四个步骤

步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)
Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$
Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	选什么损失函数?	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	选什么损失函数?
Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent
Step 4 评估模型效果	RMSE or R^2	??	Step 4 评估模型效果	RMSE or R^2	??

步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)
Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$
Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	选什么损失函数?	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	选什么损失函数?
Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent
Step 4 评估模型效果	RMSE or R^2	??	Step 4 评估模型效果	RMSE or R^2	??




步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	选什么损失函数?
Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$	选什么损失函数?
Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$		
Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent	
Step 4 评估模型效果	RMSE or R^2	??	

Sklearn / Gradient Descent	Sklearn / Gradient Descent
----------------------------	----------------------------


步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	??
Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$	??
Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	选什么损失函数?	
Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent	
Step 4 评估模型效果	RMSE or R^2	??	

是否可以沿用 MSE Loss ?

- 请分析 MSE Loss 存在的局限性 ?
 - 非凸性 (Non-convex)
 - 陷入局部最优
 - 梯度下降：不同的初始值可能会得到不同的最优解



$$\hat{y} \equiv \hat{P}(Y=1|x) \equiv \sigma(x^T \theta)$$



$$R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



交叉熵 (Cross Entropy) 损失函数

$$L(\theta, \mathbf{X}, \mathbf{y}) = -\frac{1}{n} \sum_{i=1}^n [y_i \log z_i + (1 - y_i) \log(1 - z_i)]$$

$$\ell(\theta, \mathbf{x}, y_i) = -y_i \log z_i - (1 - y_i) \log(1 - z_i)$$

假设我们只有一维特征 (且不考虑常数项)

Let $z_i = f_{\theta}(\mathbf{X}_i)$.

如果 θ 计算下面数据集的数据点的交叉熵损失

- $((\mathbf{x}, \mathbf{y})) = (5, 1)$?
- $((0, 1)? (0, 0))$?
- $((-1, 1))$?
- 如果运行SGD, θ 应该向增大还是减小的方向更新

$$f_{\theta}(\mathbf{x}) = \sigma(\theta \cdot \mathbf{x})$$

$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$



交叉熵 (Cross Entropy) 损失函数

$$\ell(\boldsymbol{\theta}, \mathbf{x}, y_i) = -y_i \log z_i - (1 - y_i) \log(1 - z_i) \quad \theta = 2$$

$$\text{For } (5, 1) : z = \sigma(5 \cdot 2) \approx 1$$

$$\ell = -1 \cdot \log 1 - 0 = 0$$

$$\text{For } (0, 1) : z = \sigma(0 \cdot 2) = \frac{1}{2}$$

$$\ell = -1 \cdot \log \frac{1}{2} - 0 = 0.693$$

$$\text{For } (-1, 1) : z = \sigma(-1 \cdot 2) = 0.119$$

$$\ell = 0 - 1 \cdot \log 0.119 = 2.129$$

深入理解交叉熵

- 考虑一组抛硬币的试验，观察到的结果为（正面=1；背面=0）
 - $\{0,0,1,1,1,1,0,0,0,0\}$
 - 假设每次抛硬币是独立同分布的 (I.I.D.)
 - 可以看做一个 Non-Input Binary Classifier，上述结果为训练数据
- 请问：给定上述结果，再抛一次，是正面的概率是多少？
 - A: 0.8 B: 0.5 C: 0.4 D: 0.2
- 为什么直觉上你会选择 0.4？
 - 符合观测数据中的频率
 - 可以极大化训练数据的似然 (Likelihood)

似然 (Likelihood) 的概念

- 考虑一个伯努利随机变量 Y 其概率分布函数为

$$P(Y = y) = \begin{cases} p & \text{if } y = 1 \\ 1 - p & \text{if } y = 0 \end{cases}$$

- 给定一组对该变量的观测数据，这组观测数据的似然与观察到这组数据点的概率成正比
- 给定一组对该变量的观测数据 $\{y_1, y_2, \dots, y_n\}$ ，这组观测数据的似然与观察到这组数据点的概率成正比
- 举例：观测数据为 $[0, 0, 1, 1, 1, 1, 0, 0, 0, 0]$ ，则数据的似然为 $p^4(1-p)^6$
- 练习：计算和时，上述训练数据的似然
- 证明：使上述似然函数最大的概率 $p = 0.4$

似然 (Likelihood) 的概念

- 考虑之前的伯努利变量, 给定一组对该变量的观测数据 $y_1, y_2, \dots, y_n$, 如何表示, 如何根据这组数据的似然

$$\prod_{i=1}^n p^{y_i} (1-p)^{(1-y_i)}$$

- 考虑更为一般的情况, 数据独立但不一定有相同的分布, 即每个用的概率 p_i , 则对一组观测数据的似然为

$$\prod_{i=1}^n p_i^{y_i} (1-p_i)^{(1-y_i)}$$

极大似然估计 (MLE)

- 给定一组随机变量 $\{Y_i\}$ 其中每个随机变量为一个伯努利变量，其参数表示为 p_i 。给定上述随机变量的观测值 $\{y_i\}$ ，求这些随机变量的参数 p_i 使得似然函数最大化 p_n ，使下述参数的似然最大化

$$\prod_{i=1}^n \frac{p_i^{y_i} (1-p_i)^{(1-y_i)}}{\text{Precision} \cdot \text{Recall}}$$

- 请论述上述极大似然估计与交叉熵的相关性
 - 极大似然估计 等价于 最小化交叉熵！**



建立与评估模型的四个步骤

步骤

Step 1 选择某种模型

Step 2 选择目标函数

Step 3 拟合模型参数

Step 4 评估模型效果

步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)
Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$
Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Cross Entropy Loss $-\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Cross Entropy Loss $-\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$
Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent
Step 4 评估模型效果	RMSE or R^2	Precision/Recall/F1	Step 4 评估模型效果	RMSE or R^2	Precision/Recall/F1
Sklearn / Gradient Descent			Sklearn / Gradient Descent		
步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)
Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$	Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$
Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Cross Entropy Loss $-\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$	Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Cross Entropy Loss $-\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$
Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent	Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent
Step 4 评估模型效果	RMSE or R^2	Precision/Recall/F1	Step 4 评估模型效果	RMSE or R^2	Precision/Recall/F1
Sklearn / Gradient Descent			Sklearn / Gradient Descent		
步骤	回归 ($y \in \mathbb{R}$)	分类 ($y \in \{0,1\}$)	Precision/Recall/F1		
Step 1 选择某种模型	线性回归 $\hat{y} = f_{\theta}(x) = x^T \theta$	逻辑回归 $\hat{P}(Y = 1 x) = \sigma(x^T \theta)$			
Step 2 选择目标函数	Mean Squared Loss $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Cross Entropy Loss $-\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$			
Step 3 拟合模型参数	Sklearn / Gradient Descent	Sklearn / Gradient Descent			
Step 4 评估模型效果	RMSE or R^2	Precision/Recall/F1			

分类算法的评测指标

- 使用测试集评测分类算法，结果如下：

- 几个关键概念

- True Positive (TP): 正确识别
- False Positive (FP): 错误识别
- True Negative (TN): 正确拒绝
- False Negative (FN): 错误拒绝



将 **TP/FP/TN/FN** 填到下表

标准答案

	正例	负例
正例	TP	FN
负例	FP	TN


预测结果

分类算法的评测指标

- 使用测试集评测分类算法，结果如下：

- 几个关键概念

- True Positive (TP): 正确识别
- False Positive (FP): 错误识别
- True Negative (TN): 正确拒绝
- False Negative (FN): 错误拒绝



- 引入新的指标

- Precision - 准确率

$$Precision = \frac{TP}{TP + FP}$$

- Recall - 召回率

$$Recall = \frac{TP}{TP + FN}$$

- F1 Score - F 值

$$F1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}}$$




分类算法的评测指标



• 课堂练习

考虑一个包含 22 个样本的数据集，其中有 11 个正例与 11 个负例。每个样本包含两个维度的特征，分别是 X_1 和 X_2 。使用者两个维度，可以 2 维平面上绘制散点图如下，其中坐标轴分别为 X_1 和 X_2 。



考虑仅使用维度 X_1 构造一个简单的分类器，如下：

- (1) 如果 $X_1 < \text{threshold}$ ，则预测样本为正例；
- (2) 如果 $X_1 \geq \text{threshold}$ ，则预测样本为负例。

其中 threshold 的位置如上图所示。

请根据以上情况回答：

(1) 请根据数据集和上述分类器，给出混淆矩阵，包括真阳性 (True Positive, 简称 TP)、假阳性 (False Positive, 简称 FP)、真阴性 (True Negative, 简称 TN) 和假阴性 (False Negative, 简称 FN) 的样本个数。(4 分)

(2) 计算上述分类器的精度 (Accuracy)。(3 分)

(3) 计算分类器的准确率 (Precision) 和召回率 (Recall) 和 F1 指标。(3 分)

提示：准确率、召回率和 F1 指标的计算公式如下：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{F1} = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}}$$