


第 9 讲：分类问题与决策树分类器

“数据科学导论”专业核心课



范举 教授

fanj@ruc.edu.cn



提纲



分类问题与典型分类模型

1. 分类问题与监督学习
2. 逻辑回归模型
3. 决策树模型
4. 案例分析：鸢尾花分类



监督学习算法分类


任务

				(二值) 分类 Y 为类别集合	回归 Y 为实数集合	结构预测 / 排序 Y 为结构类型 / 排列
模型 函数	(二值) 分类 Y 为类别集合	回归 Y 为实数集合	结构预测 / 排序 Y 为结构类型 / 排列	(二值) 分类 Y 为类别集合	回归 Y 为实数集合	结构预测 / 排序 Y 为结构类型 / 排列
	线性函数 $f(x)=(w,x)$	Perceptron, SVM	Decision tree	Perceptron, SVM	Ridge regression SVR	CRF Ranking SVM
	树	Decision tree	Regression tree	Decision tree	Regression tree	LambdaMART
	神经网络	神经网络	神经网络	神经网络	神经网络	RankNet
	叠加函数 $f(x)=\sum_i h_i(x)$ (additive model)	AdaBoost	Boosted Regression Tree	AdaBoost	Boosted Regression Tree	RankBoost
树	叠加函数			Decision tree	Regression tree	LambdaMART
神经网络	神经网络			神经网络	神经网络	RankNet
	(二值) 分类 Y 为类别集合	回归 Y 为实数集合	结构预测 / 排序 Y 为结构类型 / 排列	AdaBoost	Boosted Regression Tree	RankBoost
线性函数 $f(x)=(w,x)$	Perceptron, SVM	Ridge regression SVR	CRF	Perceptron, SVM	Ridge regression SVR	CRF
树	Decision tree	Regression tree	LambdaMART	Decision tree	Regression tree	LambdaMART
神经网络	神经网络	神经网络	RankNet	神经网络	神经网络	RankNet
叠加函数 $f(x)=\sum_i h_i(x)$ (additive model)	AdaBoost	Boosted Regression Tree	RankBoost	AdaBoost	Boosted Regression Tree	RankBoost

本课程关注 (二值) 分类 (Binary) Classification

决策树 – Decision Tree

- 决策树是分类问题中最常用的模型之一
 - 能够接受**类别型**的特征
 - 分类效果与其它分类算法相当
 - 训练 / 测试效率高
- 分类函数 f 为一棵树，称为**决策树**





二值分类数据



是否批准放贷

ID	Age	Has_Job	Own_House	Credit_Rating ?	Class
1	young	false	false	fair	No
2	young	false	false	good	No
3	young	true	false	good	Yes
4	young	true	true	fair	Yes
5	young	false	false	fair	No
6	middle	false	false	fair	No
7	middle	false	false	good	No
8	middle	true	true	good	Yes
9	middle	false	true	excellent	Yes
10	middle	false	true	excellent	Yes
11	old	false	true	excellent	Yes
12	old	false	true	good	Yes
13	old	true	false	good	Yes
14	old	true	false	excellent	Yes
15	old	false	false	fair	No


决策函数

- 中间节点：决策步骤
- 叶子节点：决策结果 / 类别标签



以下数据批准放贷吗？
A. Yes B. No

Age	Has_job	Own_house	Credit_rating
middle	false	true	fair






决策函数测试


Age	Has_Job	Own_house	Credit-Rating	Class
young	false	false	good	?

No



决策函数的选择

- 给定训练数据，可能存在多棵能够拟合数据的决策树
- 如何选择？
 - 小（简单）的树
 - 拟合精度高的树
- 决策树学习过程
 - 全局最优：NP-hard
 - 利用启发式规则建立次优决策树






决策树训练算法



- 贪心分治算法
 - 假设所有的特征都是类别类型
 - 自顶向下递归建树
 - 初始状态：所有的训练数据都在根节点上
 - 根据选择的特征，对训练数据进行划分
 - 选择特征的依据：**信息增益 (information gain)**
- 终止条件
 - 节点上的所有训练样本都属于一个类别
 - 节点上没有训练样本
 - 没有更多的特征可供选择



决策树算法



在这个结点，该选择什么样的分裂变量呢？



决策树算法

递归出口：数据属于一个类
/ 没有更多的特征供选择，生成叶子节点

选择最优划分特征：

p_0 : 划分前的混杂度

p_i : 以特征 A_i 划分后的混杂度

递归出口：数据划分收益太低

划分数据



向下递归：逐个递归生成每一棵子树

```
Algorithm decisionTree( $D, A, T$ )
1  if  $D$  contains only training examples of the same class  $c_j \in C$  then
2    make  $T$  a leaf node labeled with class  $c_j$ ;
3  elseif  $A = \emptyset$  then
4    make  $T$  a leaf node labeled with  $c_j$ , which is the most frequent class in  $D$ 
5  else //  $D$  contains examples belonging to a mixture of classes. We select a single
6    // attribute to partition  $D$  into subsets so that each subset is purer
7     $p_0 = \text{impurityEval-1}(D)$ ;
8    for each attribute  $A_i \in \{A_1, A_2, \dots, A_k\}$  do
9       $p_i = \text{impurityEval-2}(A_i, D)$ 
10   end
11   Select  $A_g \in \{A_1, A_2, \dots, A_k\}$  that gives the biggest impurity reduction,
      computed using  $p_0 - p_i$ ;
12   if  $p_0 - p_g < \text{threshold}$  then //  $A_g$  does not significantly reduce impurity  $p_0$ 
13     make  $T$  a leaf node labeled with  $c_j$ , the most frequent class in  $D$ .
14   else //  $A_g$  is able to reduce impurity  $p_0$ 
15     Make  $T$  a decision node on  $A_g$ ;
16     Let the possible values of  $A_g$  be  $v_1, v_2, \dots, v_m$ . Partition  $D$  into  $m$ 
      disjoint subsets  $D_1, D_2, \dots, D_m$  based on the  $m$  values of  $A_g$ .
17     for each  $D_j$  in  $\{D_1, D_2, \dots, D_m\}$  do
18       if  $D_j \neq \emptyset$  then
19         create a branch (edge) node  $T_j$  for  $v_j$  as a child node of  $T$ ;
20         decisionTree( $D_j, A - \{A_g\}, T_j$ ) //  $A_g$  is removed
21       end
22     end
23   end
24 end
```



选择决策特征

- 核心步骤：选择合适特征进行决策，划分数据，生成子节点
- 合适：尽量大的减少划分后子数据集的混杂度



如何度量混杂度

- 将离散的属性建模成一个随机变量 X

- 概率 $p(X = x_1)$

- 概率 $p(X = x_2)$

- 符号定义

- X : 随机变量

- x : X 的一个取值

- $p(x)$ 代表概率 $p(X=x)$

X
x_1
x_3
x_2
x_4
x_1
x_1
x_2
x_1

Column of data

aggregate
counts

X	$f(X)$
x_1	4
x_2	2
x_3	1
x_4	1

Histogram

normalize

X	$p(X)$
x_1	0.5
x_2	0.25
x_3	0.125
x_4	0.125

Probability
distribution

如何度量混杂度

- 将离散的属性建模成一个随机变量 X

- 概率 $p(X = x_1)$

- 概率 $p(X = x_2)$

- 符号定义

- X : 随机变量
- x : X 的一个取值
- $p(x)$ 代表概率 $p(X=x)$

- 引入新的符号

- $h(x) = \log_2(1/p(x))$

X	$p(X)$	$h(X)$
x1	0.5	1.0
x2	0.25	2.0
x3	0.125	3.0
x4	0.125	3.0

信息熵 - Entropy



给定一个随机变量 X , X 的熵为

$$H(X) = \sum_{c=1}^{|C|} p(x_c) h(x_c) = - \sum_{c=1}^{|C|} p(x_c) \log_2 p(x_c)$$

熵的直观解释

- 描述数据的不确定性 (Uncertainty) : 熵越高, 表述数据越难预测
- 描述信息内容 (information content) : 熵越高, 表示信息量越多




请计算右图变量 X 的熵
A. 1.75 B. 9


X	$p(X)$	$h(X)$
x1	0.5	1.0
x2	0.25	2.0
x3	0.125	3.0
x4	0.125	3.0

信息熵 - Entropy

- 均匀分布时 $p_i = \frac{1}{|C|}, i = 1, \dots, |C|$ 熵最大,
- 确定分布时 (如 $\{0, 1, 0, \dots, 0\}$) 熵最小, $H(X) = 0$
- 确定分布时 (如 $\{0, 1, 0, \dots, 0\}$) 熵最小, $H(X) = 0$
- 右图: 分布为 $\{p, 1-p\}$ 时的 $H(X)$ 随 p 变化曲线, 最大值点为 $p=0.5$.
- 右图: 分布为 $\{p, 1-p\}$ 时的 $H(X)$ 随 p 变化曲线, 最大值点为 $p=0.5$



练习题



- X 可能的取值有 4 个，服从均匀分布
- Y 可能的取值有 4 个，其中 1 个取值概率为 0.5，其余 3 个均匀分布
- Z 可能的取值有 8 个，服从均匀分布

请比较三个随机变量熵的大小



A. $X > Y > Z$ B. $X = Z > Y$ C. $Y > Z > X$ D. $Z > X > Y$

你能从不确定性或信息量的角度解释吗？

如何深入理解熵？

- 考虑 A 和 B 之间玩一个双人游戏
 - A 根据随机变量 X 的分布 $p(X)$ 选择出某个取值 x
 - B 可以问 A 若干个 Yes/No 问题来猜出 x 是多少
- 熵可以用来度量 B 所问的问题个数的期望
 - 你能证明吗？

Is $X \leq 1$? Probability of yes = 0.5.

Is $X \leq 2$? Probability of yes = 0.25.


Is $X \leq 3$? Probability of yes = 0.125.

Expected # of questions = 1.75, $H(X) = 1.75$.

X	$p(X)$	$h(X)$
x1	0.5	1.0
x2	0.25	2.0
x3	0.125	3.0
x4	0.125	3.0

如何深入理解熵？

- 考虑数据的哈弗曼编码 (Huffman Coding)
 - 请建立右表数据的哈夫曼编码树
- 熵可以用来度量平均的最短描述长度 (Average Length of shortest description)



X	p(X)	h(X)
x1	0.5	1.0
x2	0.25	2.0
x3	0.125	3.0
x4	0.125	3.0

复习：联合概率分布

- 考虑随机变量 X , Y 和 Z 的联合概率分布
 - $P(X, Y, Z)$

- 边缘概率分布
 - $P(X)$
 - $P(Y)$
 - $P(Z)$

X	Y	Z	$p(X,Y,Z)$
x1	y1	z1	0.125
x1	y2	z2	0.125
x1	y1	z2	0.125
x1	y2	z1	0.125
x2	y3	z3	0.125
x2	y3	z4	0.125
x3	y3	z5	0.125
x4	y3	z6	0.125

X	Y	$p(X,Y)$
x1	y1	0.25
x1	y2	0.25
x2	y3	0.25
x3	y3	0.125
x4	y3	0.125

X	$p(X)$
x1	0.5
x2	0.25
x3	0.125
x4	0.125

Y	$p(Y)$
y1	0.25
y2	0.25
y3	0.5

复习：条件概率

- 条件概率： $p(X|Y)$.
 - $p(X=x_1|Y=y_1)=p(X=x_1,Y=y_1)/p(Y=y_1)$.

X	Y	$p(X,Y)$	$p(X Y)$	$p(Y X)$
x1	y1	0.25	1.0	0.5
x1	y2	0.25	1.0	0.5
x2	y3	0.25	0.5	1.0
x3	y3	0.125	0.25	1.0
x4	y3	0.125	0.25	1.0

X	$p(X)$
x1	0.5
x2	0.25
x3	0.125
x4	0.125

Y	$p(Y)$
y1	0.25
y2	0.25
y3	0.5

条件熵 – Conditional Entropy

- 直观含义
 - 给定随机变量 X 和 Y 的联合概率分布，假设 Y 是已知的，我们能从 X 中获得多少信息量？
- 符号定义
 - $h(x|y) = \log_2(1/p(x|y))$
- 条件熵
 - $H(X|Y) = E_{x,y}[h(x|y)]$
 - $\sum_x \sum_y p(x,y) \log_2(1/p(x|y))$

X	Y	$p(X,Y)$	$p(X Y)$	$h(X Y)$
x1	y1	0.25	1.0	0.0
x1	y2	0.25	1.0	0.0
x2	y3	0.25	0.5	1.0
x3	y3	0.125	0.25	2.0
x4	y3	0.125	0.25	2.0

请计算右图条件熵 $H(X|Y)$

A. 1.75 B. 0.75

如何深入理解条件熵？

- 直观含义

- 给定随机变量 X 和 Y 的联合概率分布，假设 Y 是已知的，我们能从 X 中获得多少信息量？

- 考虑之前的双人游戏，思考 $H(X|Y)$

- 如果已知 $Y=y$ 了，B 要猜出 x 的问题个数期望是？
- 如果 $Y=y_1$ 0 questions
- 如果 $Y=y_2$ 0 questions
- 如果 $Y=y_3$ 1.5 questions
- 问题期望：0.75


请计算下图的条件熵

$H(Y|X)$

A. 0.75 B. 0.5

X	Y	$p(X,Y)$	$p(X Y)$	$h(X Y)$
x1	y1	0.25	1.0	0.0
x1	y2	0.25	1.0	0.0
x2	y3	0.25	0.5	1.0
x3	y3	0.125	0.25	2.0
x4	y3	0.125	0.25	2.0

两个随机变量 X 和 A



联合熵(joint entropy)

– 如 X 与 A 独立: $H(X, A) = - \sum_{c=1}^{|C|} \sum_{a=1}^{|A|} P(c, a) \log P(c, a)$

- 条件熵 (conditional entropy): 给定随机变量 A 后, X 剩余的不确定性 (熵)
– 如 X 与 A 独立: $P(c, a) = P(c)P(a) \Rightarrow H(X, A) = H(X) + H(A)$

- 条件熵 (conditional entropy): 给定随机变量 A 后, X 剩余的不确定性 (熵)
– 如 X 与 A 独立

- Chain Rule

$$H(X|A) = \sum_{a=1}^{|A|} P(A = a) H(X|A = a)$$

– 如 X 与 A 独立 $\Rightarrow H(X|A) = H(X)$

- Chain Rule


$$H(A, X) = H(A) + H(X|A)$$

条件熵与信息增益

- 信息增益 (information gain, IG) 定义为给定随机变量 A 后 X 所减少的不确定性

$$IG(X|A) = H(X) - H(X|A)$$


$$= H(X) - \sum_j P(A = a_j) H(X|A = a_j)$$



ImpurityEval-2:

$$H(X|A) = H(X|A = a1)P(A = a1) + H(X|A = a2)P(A = a2)$$

ImpurityEval-2:



信息增益性质：

信息增益性质：

$$IG(X|A) = IG(A|X)$$

$$IG(X|A) = H(X) - H(X|A)$$

举例

- X: 学生专业 ; Y: 是否喜欢玩游戏
- X: 学生专业和 Y 的分布是否喜欢玩游戏

• X和Y的分布

- $\Pr(X = \text{Math}) = 0.5, \Pr(X = \text{CS}) = 0.25,$
 $\Pr(X = \text{History}) = 0.25$

- 以2为底, 计算出 $H(X)=1.5; H(Y)=1$
 $\Pr(Y = \text{Yes}) = 0.5, \Pr(Y = \text{No}) = 0.5$

- 以2为底, 计算出 $H(X)=1.5; H(Y)=1$
 $X=\text{Math}(4 \text{ 项}): P(Y=\text{yes}|X=\text{Math})=0.5, P(Y=\text{No}|X=\text{Math})=0.5$

• $P(Y|X)$

- $X=\text{CS}(2 \text{ 项}): P(Y=\text{yes}|X=\text{Math})=1; P(Y=\text{No}|X=\text{Math})=0$
- $X=\text{Math}(4 \text{ 项}): P(Y=\text{yes}|X=\text{Math})=0.5, P(Y=\text{No}|X=\text{Math})=0.5$

$H(Y|X=\text{Math})=1$
 $X=\text{History}(2 \text{ 项}): P(Y=\text{Yes}|X=\text{History})=0; P(Y=\text{No}|X=\text{History})=1$

- $X=\text{CS}(2 \text{ 项}): P(Y=\text{yes}|X=\text{Math})=1; P(Y=\text{No}|X=\text{Math})=0$
 $H(Y|X=\text{CS})=0$

$X=\text{History}(2 \text{ 项}): P(Y=\text{Yes}|X=\text{History})=0; P(Y=\text{No}|X=\text{History})=1$

X	Y
Math	Yes
History	No
CS	Yes
Math	No
Math	No
CS	Yes
History	No
Math	Yes

练习：
 计算
 $IG(X|Y)$


选择决策特征

- 数据集的熵定义为
- 数据集D的熵定义为

$$H(D) = - \sum_{c=1}^{|C|} P_c \log P_c$$

选择特征 A 所带来的信息增益

其中 $P_c = \frac{|D_c|}{|D|}$ 属于类别c的样本数 / D中的样本数, X 对应类别标签



- 选择特征A所带来的信息增益

D_1

D_2




$$H(X) = - \sum_{c=1}^C P_c \log P_c$$

选择决策特征

$$IG(X|A) = H(X) - \left(\frac{|D_1|}{|D|} H(X|A=Yes) + \frac{|D_2|}{|D|} H(X|A=No) \right)$$


$$H(X) = - \left(\frac{46}{100} * \log \frac{46}{100} + \frac{54}{100} * \log \frac{54}{100} \right) = 0.9954$$



$$IG(X|A1) = 0.9954 - \left(\frac{0.9954}{2} + \frac{0.9954}{2} \right) = 0$$



$$H(X) = 0.9954$$



$$IG(X|A2) = 0.9954 - \left(\frac{0.4022}{2} + \frac{0}{2} \right) = 0.7943$$



关于决策树算法

- 贪心策略
 - 从根节点开始扩张，已建立的树不再改变
 - 数据划分后不再改变
 - 每次选择局部信息增益最大的特征划分数据
 - 局部最优解
- 递归算法
 - 每一个决策节点用相同的策略扩张
- IG 不是唯一的选择
 - 还可以使用 GINI 系数

使用 GINI 指数度量 Impurity

- 给定一个随机变量 X ， X 的 GINI 指数为

$$Gini(X) = \sum_{c=1}^{|C|} p(x_c)(1 - p(x_c)) = 1 - \sum_{c=1}^{|C|} p(x_c)^2$$

对于特征 A 将数据集 D 划分为 D_1 和 D_2 ，加权后的 GINI 指数

- 对于特征 A 将数据集 D 划分为 D_1 和 D_2 ，加权后的 GINI 指数

$$Gini_A(D) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

- 在决策树构建算法中：
 - ID3 算法使用的是 entropy
 - CART 算法使用的则是 gini
- 在决策树构建算法中：
 - ID3 算法使用的是 entropy
 - CART 算法使用的则是 gini



决策树算法

递归出口：数据属于一个类
/ 没有更多的特征供选择，生成叶子节点

选择最优划分特征：

p_0 : 划分前的混杂度

p_i : 以特征 A_i 划分后的混杂度

递归出口：数据划分收益太低


划分数据

向下递归：逐个递归生成每一棵子树

```
Algorithm decisionTree( $D, A, T$ )
1  if  $D$  contains only training examples of the same class  $c_j \in C$  then
2      make  $T$  a leaf node labeled with class  $c_j$ ;
3  elseif  $A = \emptyset$  then
4      make  $T$  a leaf node labeled with  $c_j$ , which is the most frequent class in  $D$ 
5  else //  $D$  contains examples belonging to a mixture of classes. We select a single
6      // attribute to partition  $D$  into subsets so that each subset is purer
7       $p_0 = \text{impurityEval-1}(D)$ ;
8      for each attribute  $A_i \in \{A_1, A_2, \dots, A_k\}$  do
9           $p_i = \text{impurityEval-2}(A_i, D)$ 
10     end
11     Select  $A_g \in \{A_1, A_2, \dots, A_k\}$  that gives the biggest impurity reduction,
        computed using  $p_0 - p_i$ ;
12     if  $p_0 - p_g < \text{threshold}$  then //  $A_g$  does not significantly reduce impurity  $p_0$ 
13         make  $T$  a leaf node labeled with  $c_j$ , the most frequent class in  $D$ .
14     else //  $A_g$  is able to reduce impurity  $p_0$ 
15         Make  $T$  a decision node on  $A_g$ ;
16         Let the possible values of  $A_g$  be  $v_1, v_2, \dots, v_m$ . Partition  $D$  into  $m$ 
            disjoint subsets  $D_1, D_2, \dots, D_m$  based on the  $m$  values of  $A_g$ .
17         for each  $D_j$  in  $\{D_1, D_2, \dots, D_m\}$  do
18             if  $D_j \neq \emptyset$  then
19                 create a branch (edge) node  $T_j$  for  $v_j$  as a child node of  $T$ ;
20                 decisionTree( $D_j, A - \{A_g\}, T_j$ ) //  $A_g$  is removed
21             end
22         end
23     end
24 end
```


决策树算法改进：数值型特征

- 上述算法只能处理类别型特征
 - 选择的特征取K个类别 → 分裂成K个子节点
- 数值型特征
 - 寻找阈值，将数值划分为(两个)多个区间
- 如何确定阈值
 - 将数据中出现的特征值从大到小排序
 - 可能的阈值有出现过特征值从大到小排序 $\{v_1, v_2, \dots, v_N\}$
 - 按照最大化信息增益原则选择一个阈值
 - 可能的阈值有 $\left\{ \frac{v_1+v_2}{2}, \frac{v_2+v_3}{2}, \dots, \frac{v_{N-1}+v_N}{2} \right\}$
 - 按照最大化信息增益原则选择一个阈值






数值型特征建立的决策树



(A) A partition of the data space



(B). The decision tree



提纲



分类问题与典型分类模型

- 1. 分类问题与监督学习
- 2. 逻辑回归模型
- 3. 决策树模型
- 4. 案例分析：鸢尾花分类

案例分析：IRIS 数据集

- 印象派艺术大师偏爱的鸢尾花




Irises
Vincent van Gogh

The Path through the Irises
Claude Monet French

案例分析：IRIS 数据集

- 鸢尾花数据集

- 统计学家、生物学家 Ronald Fisher 构建的数据集，出自论文：The use of multiple measurements in taxonomic problems
- 包含 150 个鸢尾花实例，分为以下三个类别



iris setosa



petal sepal

iris versicolor



petal sepal

iris virginica





petal sepal

```
iris_data = pd.read_csv("iris.csv")
iris_data.sample(5)
```

	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
83	84	6.0	2.7	5.1	1.6	versicolor
145	146	6.7	3.0	5.2	2.3	virginica
50	51	7.0	3.2	4.7	1.4	versicolor
0	1	5.1	3.5	1.4	0.2	setosa
22	23	4.6	3.6	1.0	0.2	setosa


示例：只使用花瓣 (Petal) 特征

```
from sklearn import tree
decision_tree_model = tree.DecisionTreeClassifier()
decision_tree_model = decision_tree_model.fit(iris_data[["PetalLengthCm", "PetalWidthCm"]], iris_data["Species"])
```





示例：只使用花瓣 (Petal) 特征

```
from sklearn import tree
decision_tree_model = tree.DecisionTreeClassifier()
decision_tree_model = decision_tree_model.fit(iris_data[["PetalLengthCm", "PetalWidthCm"]], iris_data["Species"])
```





示例：只使用花瓣 (Petal) 特征

```
from sklearn import tree
decision_tree_model = tree.DecisionTreeClassifier()
decision_tree_model = decision_tree_model.fit(iris_data[["PetalLengthCm", "PetalWidthCm"]], iris_data["Species"])
```



示例：只使用花瓣 (Petal) 特征



```
from sklearn import tree
decision_tree_model = tree.DecisionTreeClassifier()
decision_tree_model = decision_tree_model.fit(iris_data[["PetalLengthCm", "PetalWidthCm"]], iris_data["Species"])
```







示例：只使用花瓣 (Petal) 特征

```
from sklearn import tree
decision_tree_model = tree.DecisionTreeClassifier()
decision_tree_model = decision_tree_model.fit(iris_data[["PetalLengthCm", "PetalWidthCm"]], iris_data["Species"])
```



示例：只使用花瓣 (Petal) 特征

```
from sklearn import tree
decision_tree_model = tree.DecisionTreeClassifier()
decision_tree_model = decision_tree_model.fit(iris_data[["PetalLengthCm", "PetalWidthCm"]], iris_data["Species"])
```






可视化分类边界

```
from matplotlib.colors import ListedColormap
sns_cmap = ListedColormap(np.array(sns.color_palette())[0:3, :])

xx, yy = np.meshgrid(np.arange(0, 7, 0.02),
                     np.arange(0, 2.8, 0.02))

Z_string = decision_tree_model.predict(np.c_[xx.ravel(), yy.ravel()])
categories, Z_int = np.unique(Z_string, return_inverse=True)
Z_int = Z_int
Z_int = Z_int.reshape(xx.shape)
cs = plt.contourf(xx, yy, Z_int, cmap=sns_cmap)
sns.scatterplot(data = iris_data, x = "PetalLengthCm", y="PetalWidthCm", hue="Species");
```



评测分类的优劣：


```
from sklearn.metrics import accuracy_score
predictions = decision_tree_model.predict(
    iris_data[["PetalLengthCm", "PetalWidthCm"]])
accuracy_score(predictions, iris_data["Species"])
```

0.9933333333333333

思考：这样评测决策树好吗？


划分训练集 / 测试集

- 将数据集按照 110/40 划分，分别形成训练集与测试集
- 在训练集上构建决策树，分别在训练集与测试集上评测



Train Accuracy = 0.99

>




Test Accuracy = 0.95





过拟合问题

- 过拟合：机器学习算法拟合噪声数据，而不是数据中的有意义规律
- 产生的现象：在训练数据上得到的精度远大于在测试数据上得到的精度
- 过拟合问题不仅仅存在于决策树学习，是机器学习算法面临的共同问题
- 原因
 - 训练数据量不够
 - 模型过于复杂，模型参数过多
 - 决策树：太深、节点太多。有些节点是在噪声和离群数据的干扰下建立
- 解决方案
 - 降低模型复杂度
 - 决策树：减少节点数目，剪枝



可能过拟合 如何解决过拟合？



课后练习：
通过调节

DecisionTreeClassifier 的
参数，如：

- max_depth
- min_impurity_split
- min_samples_leaf

测试是否解决 overfitting




关于决策树的其他话题



- 输出变量也为数值型：回归问题
 - Regression tree
- 计算复杂度
- IG 以外的数据划分原则
- 决策树可以和 Boosting 相结合
 - Multiple Additive Regression Trees (MART)



课堂练习



计算左侧节点
划分后带来的
信息熵和 Gini
指数的变化，
并给出计算过
程