



数据科学导论 —— 期末复习



范举教授

fanj@ruc.edu.cn



期末考试

- 考试时间
 - 2024年1月3日（周三）
 - 8:00 – 10:00
- **闭卷考试**
- 考试地点：求是0220
- 考题类型（简答/计算题）
 - 数据准备与数据分析
 - 机器学习
 - 文本数据分析
 - 图数据分析



课程主要内容

- 数据准备与数据分析
 - 数据科学基本概念与流程
 - 数据预处理：数据缺失值处理、异常值检测、数据规范化
- **机器学习**
- **文本数据分析**
- **图数据分析**



课程主要内容

- **机器学习**

- 基础、一些基本概念
- 评价：准确率、召回率、F值
- 线性回归（包含设计矩阵、解析解、梯度下降等）
- 决策树分类器（包含信息熵、条件熵、信息增益、决策树构建等）
- 线性分类器（感知机、逻辑回归等）
- 聚类K-Means
- GMM/EM算法



课程主要内容

- **文本数据分析**
 - 文本的预处理
 - 文本的独热表示
 - 文本的稠密表示
 - 文本分类



课程主要内容

- 图数据分析

- 基础知识
- Centrality (degree、closeness、betweenness中心度)
- PageRank的计算
- 社区检测 (模块度计算 , louvain算法)
- 影响力 (传播模型、Degree Discount算法)

$$\Delta Q(i \rightarrow c) = \frac{1}{n} \left(k_{i,n} - \frac{k_i \sum total}{2m} \right)$$

数据值的类型

- Nominal 标记值
 - ID、姓名、电话等，和数据项个数相当
- Categorical 离散值
 - 邮编、性别、型号等
- Ordinal 排序型
 - 分数分级A、B、C等
- Numerical 数值型
 - 度量值，薪水、高度等
- Interval 区间型
 - 数据值范围
- Ratio 比例

定性

定量

信息量增加



数据缺失

- 有数据的地方，通常也就有缺失的数据
 - 我们没有上帝视角
- 数据科学，必须面对数据缺失的问题
 - 仪器故障
 - 因为与以它记录冲突被删除
 - 人为因数没有输入
 - 当初录入数据时数据项没有被重视
 - 数据变化没有被记录
- 缺失数据对分析建模有很大影响
 - 忽略还是弥补，这是个问题

缺失值处理

- 忽略记录：保留全的记录
- 忽略属性：保留全的属性
- 手动填充：可行吗？
- 用一个全局值代替，例如-1， unknown
- 使用对应属性的平均值
- 使用相同类标签样本对应属性上的平均值
- 用最大可能的值推理
 - 如找最相似的点推理缺失值
 - 使用贝叶斯或决策树推理
- 缺失值填充：猜的越多，离真实数据越远





数值间的转换

- 排序型转换成数值型
 - A -> 4.0 A- ->3.7
 - B -> 3.3 B- ->3.0
- 多值属性处理
 - 颜色、国家、省/州等有限数值，可以用数值编号字典化处理数据
- ID属性
 - 一般保持不变。过长且带冗余信息的属性值，可以做压缩，注意在不同数据集上压缩ID解释的一致性
- 属性值分组
 - 省份按区域换分成5-6组


数据离散化处理

- 把连续型的数值数据分成区间型数据Binning
 - 如4分制到A/B/C转换
 - 可以减少数据量、压缩数据
- 等宽度划分离散化Equal-Width Binning
 - 优点：简单、易懂
 - 缺点：分成多少个桶？
 - 受噪音影响大



数据离散化处理

- 等高划分离散化 Equal-Depth Binning
 - 对比一下与EW的优缺点？



- 请将下面数据用EW和ED离散化处理
 - 13,15,16,16,19,20,21,22,22,25,30,33,35,35,36,40,45

4-13=32

的桶

4 bin. 8 width.



4 bin.
3552.

发现异常值 (outlier)

- 单变量
 - 统计方法 , $k=2$ or 3

3σ规则!

$$(\bar{x} - ks, \bar{x} + ks)$$



发现异常值 (outlier)



- 单变量

- 超级异常值 :

$(Q1-3 \times IQR, Q3+3 \times IQR)$, where $IQR=Q3-Q1$

- 普通异常值

$(Q1-1.5 \times IQR, Q3+1.5 \times IQR)$



发现异常值 (outlier)

- 单变量
 - 统计方法：k倍标准差之外 ($k = 2, 3$)
 - 思考：这种方法存在什么问题？
 - 考虑一组年龄数据

1 20 21 21 22 26 33 35 36 37 39 42 45 47 54 57 61 62 400

- 计算出：均值为56；标准差为83 → 两倍标准差区间 $[-109, 221]$
- 为什么会出现这种情况？
- 均值Mean对异常值很敏感！
- 怎么解决？中位数Median

数据归一化(normalization)处理

- Min-max归一化

$$v' = \frac{v - \min_v}{\max_v - \min_v} (\text{new_max}_v - \text{new_min}_v) + \text{new_min}_v$$

- Z-score归一化

– 基于统计

$$v' = \frac{v - \bar{v}}{\sigma_v}$$

$$\frac{x - \mu}{\sigma}$$

- 十位数归一化

– j取值刚好让最大的数小于等于1





$$v' = \frac{v}{10^j}$$



Age	min-max (0-1)	z-score	dec. scaling
-----	---------------	---------	--------------

44	0.421	0.450	0.44
35	0.184	-0.450	0.35
34	0.158	-0.550	0.34
34	0.158	-0.550	0.34
39	0.289	-0.050	0.39
41	0.342	0.150	0.41
42	0.368	0.250	0.42
31	0.079	-0.849	0.31
28	0.000	-1.149	0.28
30	0.053	-0.949	0.3
38	0.263	-0.150	0.38
36	0.211	-0.350	0.36
42	0.368	0.250	0.42
35	0.184	-0.450	0.35
33	0.132	-0.649	0.33
45	0.447	0.550	0.45
34	0.158	-0.550	0.34
65	0.974	2.548	0.65
66	1.000	2.648	0.66
38	0.263	-0.150	0.38

28	minimum	
66	maximum	
39.50	average	
10.01	standard deviation	





数据建模的四个步骤

- **选择某种模型 – Model**
 - 回归模型 – Linear Regression
 - 分类模型 – Logistic Regression, Perceptron, SVM, Decision Tree
 - 聚类模型 – K-Means, GMM
- **选择目标函数 – Objective**
 - 经验分享最小 – Empirical Risk Minimization
 - 极大似然估计 – Maximum Likelihood Estimation
- **优化目标函数 – Optimization**
 - 最小化/最大化目标函数
- **评测模型效果 – Evaluation**
 - 评测指标



线性回归模型 – Linear Regression

- 多元线性回归 (Multiple Linear Regression, MLR)
 - 在简单 (一元) 线性回归SLR模型基础上添加更多的独立变量
- 针对每个数据点，添加一个常数特征 $x_0 = 1$ ，得到

$$\hat{y} = f_{\theta}(x) = x^T \theta = \sum_{j=0}^d \theta_j x_j$$

- MLR模型举例：波士顿房价数据集
 - 输入变量
 - RM: average number of rooms per dwelling
 - LSTAT: % lower status of the population
 - 输出变量
 - Price: price of house

应该如何建立
MLR模型？

将线性回归表示为矩阵相乘

- 考虑之前波士顿房价的例子

	BIAS	RM	LSTAT
0	1	6.575	4.98
1	1	6.421	9.14
2	1	7.185	4.03
3	1	6.998	2.94
4	1	7.147	5.33
...	...	...	...
501	1	6.593	9.67
502	1	6.120	9.08
503	1	6.976	5.64
504	1	6.794	6.48
505	1	6.030	7.88

506 rows × 3 columns

$$\theta = \begin{bmatrix} -1.36 \\ 5.09 \\ -0.64 \end{bmatrix}$$

练习：

- 请计算 $\hat{y}_4$

$$x^T \theta = (1, 7.147, 5.33)$$

设计矩阵 (Design Matrix)

- 给定训练集，我们可以定义设计矩阵

$$\mathbb{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & x_{13} & \cdots & x_{1d} \\ 1 & x_{21} & x_{22} & x_{23} & \cdots & x_{2d} \\ 1 & x_{31} & x_{23} & x_{33} & \cdots & x_{3d} \\ 1 & x_{41} & x_{42} & x_{43} & \cdots & x_{4d} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} & \cdots & x_{nd} \end{bmatrix}$$

每行代表一个数据实例（数据点）
如数据点1的特征

每列代表一个数据特征（输入变量）
如所有点在特征1上的取值

将线性回归表示为矩阵相乘

- 基于设计矩阵，MLR模型表示为

$$\hat{\mathbf{Y}} = \mathbf{X}\boldsymbol{\theta}$$



$$\begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \\ \hat{y}_4 \\ \vdots \\ \hat{y}_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} & x_{13} & \cdots & x_{1d} \\ 1 & x_{21} & x_{22} & x_{23} & \cdots & x_{2d} \\ 1 & x_{31} & x_{32} & x_{33} & \cdots & x_{3d} \\ 1 & x_{41} & x_{42} & x_{43} & \cdots & x_{4d} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} & \cdots & x_{nd} \end{bmatrix}$$

特征

参数

$$\begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \\ \theta_4 \\ \vdots \\ \theta_d \end{bmatrix}$$

d+1

n x d

b x 1



$$\hat{y}_2 = \mathbf{X}_{2,:} \boldsymbol{\theta} = \theta_0 + \theta_1 x_1 + \cdots + \theta_d x_d$$

$\theta_0 + x_{11}\theta_1 + x_{12}\theta_2 + \cdots + x_{1d}\theta_d$

设计矩阵 (Design Matrix)

- 考虑之前波士顿房价的例子

	BIAS	RM	LSTAT
0	1	6.575	4.98
1	1	6.421	9.14
2	1	7.185	4.03
3	1	6.998	2.94
4	1	7.147	5.33
...	...	...	...
501	1	6.593	9.67
502	1	6.120	9.08
503	1	6.976	5.64
504	1	6.794	6.48
505	1	6.030	7.88

506 rows × 3 columns

- 基于设计矩阵，MLR模型表示为


$$\hat{Y} = X\theta$$

θ 参数



请结合左图分别说出 $\hat{Y}$ 、 X 和 θ 的维数
A. 506*1 B. 506*3 C. 3*506 D. 3*1

$X^T = 3 \times 506 \times 506 \times 3$
 $506 \times 3 \rightarrow X \quad 3 \times 1$



MSE目标函数的矩阵形式

- 给定线性回归模型，均方误差MSE可以写为

$$R(a, b) = \frac{1}{2n} \sum_{i=1}^n (y_i - (a + bx_i))^2$$

$y - x\theta$

- 给定线性回归的矩阵形式，我们有

$$R(\theta) = \frac{1}{2n} \|\mathbb{Y} - \mathbb{X}\theta\|_2^2$$

- 注：

– $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$ 称为向量 x 的L2范数 (L2 Norm)

使用梯度下降求解多元线性回归模型

- 给定线性回归的矩阵形式，我们有

$$R(\theta) = \frac{1}{2n} \|\mathbb{Y} - \mathbb{X}\theta\|_2^2$$

- 请推导出梯度向量 $\nabla_{\theta} R(\theta)$

$\mathbb{X}\theta - \mathbb{Y} = \begin{pmatrix} \frac{1}{3} - 4 \\ \frac{1}{3} - 1 \\ \frac{2}{3} - 9 \end{pmatrix} = \begin{pmatrix} -\frac{11}{3} \\ -\frac{2}{3} \\ -\frac{25}{3} \end{pmatrix}$

$$\nabla_{\theta} R(\theta) = \frac{1}{n} \mathbb{X}^T (\mathbb{X}\theta - \mathbb{Y}) = \frac{1}{n} \sum_{i=1}^n (x_i^T \theta - y_i) \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{id} \end{bmatrix}$$

$\Rightarrow \begin{pmatrix} \frac{1}{3} \\ \frac{1}{3} \\ \frac{2}{3} \end{pmatrix} \times 1 + \begin{pmatrix} \frac{2}{3} \\ \frac{1}{3} \\ \frac{5}{3} \end{pmatrix} \times 2 + \begin{pmatrix} \frac{1}{3} \\ \frac{1}{3} \\ \frac{5}{3} \end{pmatrix} \times 1 = \begin{pmatrix} \frac{1}{3} \\ \frac{10}{3} \\ \frac{22}{3} \end{pmatrix}$

课堂练习：
 - 给定一组训练数据：(2,4), (5,1), (8,9)
 - 请计算 $\theta = [\frac{1}{2}, \frac{5}{6}]$ 时的梯度向量 $\nabla_{\theta} R(\theta)$



● 随机梯度下降 (Stochastic Gradient Descent, SGD)

- 主流机器学习 (深度学习) 的参数优化方法

一个 epoch

1. Initialize $\theta^{(0)} \leftarrow$ Zero, Random, etc.
2. For t from 0 to convergence:
3. Shuffle ($\mathbb{X}, \mathbb{Y}$)
4. For each B-sized minibatch ($\mathbb{X}_b, \mathbb{Y}_b$) in ($\mathbb{X}, \mathbb{Y}$)
5. $\theta^{(t+1)} \leftarrow \theta^{(t)} - \alpha \text{ Gradient } (\mathbb{X}_b, \mathbb{Y}_b, \theta^{(t)})$
6. End For
7. End For

- Shuffle: 将数据做一次随机化排序
- ($\mathbb{X}_b, \mathbb{Y}_b$): 大小为B的一个mini-batch



课堂练习

$$\begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 2 \end{pmatrix} \quad \begin{pmatrix} 11 \\ 21 \\ 35 \end{pmatrix}$$

考虑在下面的训练集上训练一个多元线性回归模型。
该数据集包含两个特征维度，表示为 X_1 和 X_2 ，以及一个预测目标 Y 。

X_1	X_2	Y
1	1	11
2	1	21
1	2	22
2	2	35

现在采用梯度下降算法进行求解。初始参数如下，其中 θ_0 为截距， θ_1, θ_2 分别为 X_1 和 X_2 的参数。

θ_0	θ_1	θ_2
5	5	5

请根据以上信息回答下面的问题：

(1) 请列出设计矩阵 $\mathbf{X}$ 。(2 分)

(2) 如果采用 Mini-batch Gradient Descent 算法进行计算，即在每次迭代中选取一个包含两个样本的 Mini-batch 进行梯度计算。请根据梯度计算公式，计算在初始参数的情况下，如果一个 Mini-batch 采样到的是样本 1 和样本 2，此时的梯度应为多少？(4 分)

(3) 根据上述梯度计算结果，并采用 0.1 的学习率，对上述参数 $\theta_0, \theta_1, \theta_2$ 进行更新，并给出更新后的参数值。(4 分)


提示：本题考虑多元线性回归的损失函数为 $R(\theta) =$

$\frac{1}{2n} \|\mathbf{Y} - \mathbf{X}\theta\|_2^2$ ，损失函数对 θ 的梯度为 $\nabla_{\theta} R(\theta) = \frac{1}{n} \mathbf{X}^T (\mathbf{X}\theta - \mathbf{Y})$ ，其中 $\mathbf{X}$ 为设计矩阵， θ 为参数向量， $\mathbf{Y}$ 为真实 Y 值向量。

$$\frac{1}{n} \mathbf{X}^T (\mathbf{X}\theta - \mathbf{Y}) = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 2 \end{pmatrix} \left(\begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 5 \\ 5 \end{pmatrix} - \begin{pmatrix} 11 \\ 21 \end{pmatrix} \right)$$

决策树 – Decision Tree

- 决策树是分类问题中最常用的模型之一
 - 能够接受**类别型**的特征
 - 分类效果与其它分类算法相当
 - 训练/测试效率高
- 分类函数 f 为一棵树，称为**决策树**



决策树构建算法

递归出口：数据属于一个类/
没有更多的特征供选择，生
成叶子节点

选择最优划分特征：

p_0 : 划分前的混杂度

p_i : 以特征 A_i 划分后的混杂度

递归出口：数据划分收益太低

划分数据

向下递归：逐个递归生成每
一棵子树

```

1  Algorithm decisionTree( $D, A, T$ )
2  if  $D$  contains only training examples of the same class  $c_j \in C$  then
3    make  $T$  a leaf node labeled with class  $c_j$ ;
4  elseif  $A = \emptyset$  then
5    make  $T$  a leaf node labeled with  $c_j$ , which is the most frequent class in  $D$ 
6  else //  $D$  contains examples belonging to a mixture of classes. We select a single
7    // attribute to partition  $D$  into subsets so that each subset is purer
8     $p_0 = \text{impurityEval-1}(D)$ ;
9    for each attribute  $A_i \in \{A_1, A_2, \dots, A_k\}$  do
10      $p_i = \text{impurityEval-2}(A_i, D)$ 
11   end
12   Select  $A_g \in \{A_1, A_2, \dots, A_k\}$  that gives the biggest impurity reduction,
13   computed using  $p_0 - p_i$ ;
14   if  $p_0 - p_g < \text{threshold}$  then //  $A_g$  does not significantly reduce impurity  $p_0$ 
15     make  $T$  a leaf node labeled with  $c_j$ , the most frequent class in  $D$ .
16   else //  $A_g$  is able to reduce impurity  $p_0$ 
17     Make  $T$  a decision node on  $A_g$ ;
18     Let the possible values of  $A_g$  be  $v_1, v_2, \dots, v_m$ . Partition  $D$  into  $m$ 
19     disjoint subsets  $D_1, D_2, \dots, D_m$  based on the  $m$  values of  $A_g$ .
20     for each  $D_j$  in  $\{D_1, D_2, \dots, D_m\}$  do
21       if  $D_j \neq \emptyset$  then
22         create a branch (edge) node  $T_j$  for  $v_j$  as a child node of  $T$ ;
23         decisionTree( $D_j, A - \{A_g\}, T_j$ ) //  $A_g$  is removed
24       end
25     end
26   end
27 end

```

信息熵 - Entropy



给定一个随机变量 X ， X 的熵为

$$H(X) = \sum_{c=1}^{|C|} p(x_c) h(x_c) = - \sum_{c=1}^{|C|} p(x_c) \log_2 p(x_c)$$

- 熵的直观解释

- 描述数据的不确定性 (Uncertainty) : 熵越高, 表述数据越难预测
- 描述信息内容 (information content) : 熵越高, 表示信息量越多



请计算右图变量 X 的熵

A. 1.75 B. 9

$$0.5 \times 1 + 0.25 \times 2 + 0.125 \times 3 \times 2$$

$$= 0.5 + 0.5 + 0.75 = 1.75$$

X	p(X)	h(X)
x1	0.5	1.0
x2	0.25	2.0
x3	0.125	3.0
x4	0.125	3.0

条件熵 – Conditional Entropy

$$h(x|y) = \log \frac{1}{p(x|y)} = -\log p(x|y)$$

- 直观含义
 - 给定随机变量X和Y的联合概率分布，假设Y是已知的，我们能从X中获得多少信息量？
- 符号定义
 - $h(x|y) = \log_2(1/p(x|y))$
- 条件熵
 - $H(X|Y) = E_{x,y}[h(x|y)]$
 - $\sum_x \sum_y p(x,y) \log_2(1/p(x|y))$

X	Y	p(X,Y)	p(X Y)	h(X Y)
x1	y1	0.25	1.0	0.0
x1	y2	0.25	1.0	0.0
x2	y3	0.25	0.5	1.0
x3	y3	0.125	0.25	2.0
x4	y3	0.125	0.25	2.0



请计算右图条件熵**H(X|Y)**

A. 1.75 B. 0.75



$$\sum p(x,y) h(x|y)$$

$$\frac{1}{8} \times 4 + 0.25 = 0.75$$

选择决策特征

- 数据集D的熵定义为


$$H(X) = - \sum_{c=1}^{|C|} P_c \log P_c$$

其中 $P_c = \frac{\text{属于类别}c\text{的样本数}}{D\text{中的样本数}}$, X 对应类别标签

- 选择特征A所带来的信息增益

$$IG(X|A) = H(X) - \left(\frac{|D_1|}{|D|} H(X|A = \text{Yes}) + \frac{|D_2|}{|D|} H(X|A = \text{No}) \right)$$

- 注意：特征A可以有多个取值




选择决策特征

$$H(X) = - \sum_{c=1}^{|C|} P_c \log P_c$$

$$IG(X|A) = H(X) - \left(\frac{|D_1|}{|D|} H(X|A = \text{Yes}) + \frac{|D_2|}{|D|} H(X|A = \text{No}) \right)$$

$$H(X) = - \left(\frac{46}{100} * \log \frac{46}{100} + \frac{54}{100} * \log \frac{54}{100} \right) = 0.9954$$




0.9954 0.9954

$$IG(X|A1) = 0.9954 - \left(\frac{0.9954}{2} + \frac{0.9954}{2} \right) = 0$$



$\frac{|D_1|}{|D|}$

$$H(X) = 0.9954$$



0.4022 0

$$IG(X|A2) = 0.9954 - \left(\frac{0.4022}{2} + \frac{0}{2} \right) = 0.7943$$



课堂练习

考虑一个包含 100 个样本的数据集，这些样本隶属于 2 个类别，其中类别 1 有 42 个样本，类别 2 有 58 个样本。该数据集有 A1、A2、A3 三个属性，这三个属性都各有 2 个取值。请在该数据集上构建决策树分类器。

如果分别以 A1、A2、A3 作为第一个划分属性，那么数据集划分以后得到的两个数据子集，隶属于类别 1 和类别 2 的情况总结如下表所示。比如，以 A1 对数据集进行划分，得到数据子集 1 和数据子集 2。其中，数据子集 1 中有 21 个类别 1 的样本、29 个类别 2 的样本；数据子集 2 中有 21 个类别 1 的样本，29 个类别 2 的样本。

以 A1 作为第一个划分属性	数据子集 1: 类别 1 有 21 个样本; 类别 2 有 29 个样本	数据子集 2: 类别 1 有 21 个样本; 类别 2 有 29 个样本
以 A2 作为第一个划分属性	数据子集 1: 类别 1 有 42 个样本; 类别 2 有 8 个样本	数据子集 2: 类别 1 有 0 个样本; 类别 2 有 50 个样本
以 A3 作为第一个划分属性	数据子集 1: 类别 1 有 37 个样本; 类别 2 有 13 个样本	数据子集 2: 类别 1 有 5 个样本; 类别 2 有 45 个样本

- 请基于上述信息，计算：
 - (1) 整个数据集的信息熵？列出计算式即可，可不约减与计算得数。（3分）
 - (2) 分别以A1、A2、A3作为第一个划分属性，对数据集进行划分以后的条件熵？列出计算式即可，可不约减与计算得数。（5分）
 - (3) 请指出应该选择哪个属性作为第一个划分属性，并解释原因。（2分）



逻辑回归模型 – Logistic Regression

- 逻辑回归模型
 - 将回归问题进行转化——估计条件概率 $P(Y = 1|X)$
- 在线性回归输出的结果上加一个非线性函数 σ

$$\hat{P}(Y = 1|x) = \sigma(x^T \theta) = \frac{1}{1 + e^{-x^T \theta}}$$

- 请推导以下公式：

$$\log \left(\frac{P(Y = 1|X)}{P(Y = 0|X)} \right) = \boxed{?}$$

$$f_{\theta}(x) = \sigma(\theta \cdot x)$$
$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$



交叉熵 (Cross Entropy) 损失函数

$$L(\theta, \mathbf{X}, \mathbf{y}) = -\frac{1}{n} \sum_{i=1}^n [y_i \log z_i + (1 - y_i) \log(1 - z_i)]$$

☆ $\ell(\theta, \mathbf{x}, y_i) = -y_i \log z_i - (1 - y_i) \log(1 - z_i)$

假设我们只有一维特征 (且不考虑常数项)

如果 $\theta = 2$, 计算下面数据点的交叉熵损失

- $(x, y) = (5, 1)$?
- $(0, 1)$? $(0, 0)$?
- $(-1, 1)$?

- 如果运行SGD, θ 应该向增大还是减小的方向更新

Let $\underline{z_i = f_{\theta}(\mathbf{X}_i)}$. $\frac{1}{1+e^{-\theta x}}$

$$f_{\theta}(\mathbf{x}) = \sigma(\theta \cdot \mathbf{x})$$

$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$

熵↓.
 $f_{\theta}(x) = \frac{1}{1+e^{-x^T\theta}}$ ↓

$\theta \downarrow$.



交叉熵 (Cross Entropy) 损失函数

$$\ell(\boldsymbol{\theta}, \mathbf{x}, y_i) = -y_i \log z_i - (1 - y_i) \log(1 - z_i) \quad \theta = 2$$

$$\sigma(0 \times 2) = \sigma(0) = \frac{1}{1 + e^{-0}} = 1$$

$$\text{For } (5, 1) : z = \sigma(5 \cdot 2) \approx 1$$

$$\ell = -1 \cdot \log 1 - 0 = 0$$

$$\text{For } (0, 1) : z = \sigma(0 \cdot 2) = \frac{1}{2}$$


$$\ell = -1 \cdot \log \frac{1}{2} - 0 = 0.693$$

$$\text{For } (-1, 1) : z = \sigma(-1 \cdot 2) = 0.119$$

$$\ell = 0 - 1 \cdot \log 0.119 = 2.129$$

$$-1 \times \log 0.119 - (1) \log (1 - 0.119)$$

感知机线性分类器




$$f(\mathbf{x}; \mathbf{w}, b) = \text{sgn}(\langle \mathbf{w}, \mathbf{x} \rangle + b)$$

权重向量 $\nwarrow$ bias


所有的模型(分类面)错误率为0, 哪个最好?

问题建模: 通过线性函数的符号 (sgn)

估计条件概率 $P(Y = 1|X)$



分析案例




- 训练样本

$$X = \begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 2 & 0 \\ 3 & 0 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ +1 \\ +1 \end{bmatrix}$$

- 训练目标

$$f(\mathbf{x}; \mathbf{w}, b) = \text{sgn}(\langle \mathbf{w}, \mathbf{x} \rangle + b)$$





学习模型的损失函数

- 学习目标

- 在训练集上，减少错误的分类，最终实现所有分类正确（线性可分）

- 针对任一训练样本 $(\mathbf{x}_i, y_i)$ ，分类错误表示为

- $-y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) > 0$

$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) < 0$ 错误

- 针对整个训练集，损失函数Loss Function可以定义为

- $L(\mathbf{w}, b) = -\sum_{\mathbf{x}_i \in M} y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b)$

- 其中 M 为所有错误分类实例的集合



随机梯度下降

- 随机梯度下降 (Stochastic Gradient Descent)
 - 选择任意分类错误实例($\mathbf{x}_i, y_i$)
 - 按照梯度的负方向更新参数
 - η : 学习率 Learning Rate

$$\mathbf{w} = \mathbf{w} - \eta \nabla_{\mathbf{w}} L(\mathbf{w}, b) = \mathbf{w} + \eta y_i \mathbf{x}_i$$

$$b = b - \eta \nabla_b L(\mathbf{w}, b) = b + \eta y_i$$


- 线性感知机(Perceptron)算法
 - 输入: 训练数据 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, 学习步长 $\eta > 0$
 - 输出: 感知机模型 $\mathbf{w}, b$
1. $(\mathbf{w}, b) \leftarrow$ 随机值
 2. $R \leftarrow \max_i |\mathbf{x}_i|$
 3. **repeat**
 4. 选取数据 $(x_i, y_i) \in D$
 5. **if** $y_i f(\mathbf{x}_i) \leq 0$ **then**
 6. $\mathbf{w} \leftarrow \mathbf{w} + \eta y_i \mathbf{x}_i$
 7. $b \leftarrow b + \eta R y_i$
 8. **end if**
 9. **until** convergence



课堂练习

- 请按照不同的顺序输入实例，观察最后的结果
 - $X = [[0,0],[2,2],[2,0],[3,0]]$; $y = [-1,-1,1,1]$
 - $X = [[0,0],[2,0],[3,0],[2,2]]$; $y = [-1,1,1,-1]$

$w = (0, 0)$ $b = 0$
 $y \cdot (w \cdot x + b) < 0$
更新 w, b





EM算法深入 – 混合高斯模型

注：这部分属于了解内容

- 将简单的模型混合起来成为复杂的模型

$$P(\mathbf{x}_i) = \sum_k \pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

其中 π_k 表示数据属于第 k 个子模型的概率 $\sum_k \pi_k = 1, \pi_k \geq 0$



混合高斯模型

- 将简单的模型混合起来成为复杂的模型


$$P(\mathbf{x}_i) = \sum_k \pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad \sum_k \pi_k = 1, \pi_k \geq 0$$

- 如何基于一组观测数据 $\mathbf{X}$ ，“还原”出背后的模型？

$$\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$$




问题抽象：如果已知数据服从某个特定的分布，并有一组观测到的数据样本，对分布的参数进行估计



极大似然估计 - Maximum Likelihood Estimate

- 举例：已知数据服从高斯分布，且我们观测到以下数据



根据左侧给出的观测数据，
你觉得哪个高斯分布函数比
较合适呢？

- ☒ A. 分布1
- ☐ B. 分布2
- ☐ C. 分布3
- ☐ D. 分布4



极大似然估计 - Maximum Likelihood Estimate

- 基本思想
 - 找到一组参数，使得已观测到样本集的联合概率最大化
- 似然函数
 - 假设有样本集 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ 服从高斯分布 $N(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma})$
 - 假设样本抽样是独立的，那么我们同时抽到这 N 个样本的概率是抽到每个样本概率的乘积，也就是样本集 $\mathbf{Y}$ 的联合概率。
 - 此联合概率即为似然函数

$$L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \prod_{i=1}^N p(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad \xrightarrow{\text{对数形式}} \quad \ln L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{i=1}^N \ln p(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma})$$



极大似然估计 - Maximum Likelihood Estimate

- 基本思想
 - 找到一组参数，使得已观测到样本集的联合概率最大化
- 最大化似然函数
 - 假设有样本集 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ 服从高斯分布 $N(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma})$

$$\max \ln L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \max \sum_{i=1}^N \ln p(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma})$$

- 请写出1-D高斯分布的例子

- $\ln L(\mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^N (x - \mu)^2 - \frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln 2\pi$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

课后练习：
请推导极大似然估计
的参数 μ_{ML} 和 σ_{ML}^2

混合高斯分布的极大似然估计

$$L = \ln p(\mathbf{X}|\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{i=1}^N \ln \sum_k \pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

- 针对 $\boldsymbol{\mu}_k$ 求导

$$\frac{\partial L}{\partial \boldsymbol{\mu}_k} = - \sum_{i=1}^N \frac{\pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_j \pi_j N(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \boldsymbol{\Sigma}_k (\mathbf{x}_i - \boldsymbol{\mu}_k) = 0$$

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} \mathbf{x}_i$$

$$\text{Where } N_k = \sum_{i=1}^N \gamma_{ik}$$

混合高斯分布的极大似然估计

$$L = \ln p(\mathbf{X}|\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{i=1}^N \ln \sum_k \pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

- 类似的方式求解 $\boldsymbol{\Sigma}_k$ 与 π_k

$$\boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T$$

$$\pi_k = \frac{N_k}{N}$$


$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} \mathbf{x}_i$$


$$\text{Where } N_k = \sum_{i=1}^N \gamma_{ik}$$

使用EM算法进行交替优化

- Boot Step:

- Initialize K clusters: $C_1, \dots, C_K$
 (μ_j, Σ_j) and $P(C_j)$ for each cluster j .

初始化参数

$$\{\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, \pi_k\}$$

- Iteration Step:

- Estimate the cluster of each data point

$$p(C_j | x_i) = \frac{p(x_i | C_j) \cdot p(C_j)}{p(x_i)} = \frac{p(x_i | C_j) \cdot p(C_j)}{\sum_j p(x_i | C_j) \cdot p(C_j)}$$

E(xpectation) Step

$$\gamma_{ik} = \frac{\pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_j \pi_j N(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}$$

- Re-estimate the cluster parameters

M(aximization) Step


$$\mu_j = \frac{\sum_i p(C_j | x_i) \cdot x_i}{\sum_i p(C_j | x_i)} \quad \Sigma_j = \frac{\sum_i p(C_j | x_i) \cdot (x_i - \mu_j) \cdot (x_i - \mu_j)^T}{\sum_i p(C_j | x_i)} \quad p(C_j) = \frac{\sum_i p(C_j | x_i)}{N}$$

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} \mathbf{x}_i$$

$$\boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k) (\mathbf{x}_i - \boldsymbol{\mu}_k)^T$$

$$\pi_k = \frac{N_k}{N}$$

使用EM算法进行交替优化



K-Means与EM

- K-Means是EM的特殊情况
 - 只考虑类簇的均值，而不考虑类簇方差
 - 优化目标等价于极大似然估计

$$\Sigma_k = \epsilon I$$

$$\gamma_{ik} = \frac{\pi_k N(\mathbf{x}_i | \boldsymbol{\mu}_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_i | \boldsymbol{\mu}_j, \Sigma_j)} = \frac{\pi_k \exp\{-\|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 / 2\epsilon\}}{\sum_j \pi_j \exp\{-\|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2 / 2\epsilon\}}$$

$$\epsilon \rightarrow 0 \quad \longrightarrow \quad \gamma_{ik} \rightarrow r_{ik} = \begin{cases} 1 & \text{if } k = \arg \min_k \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \\ 0 & \text{otherwise} \end{cases}$$

$$\epsilon \rightarrow 0 \quad \longrightarrow \quad E[L] \rightarrow -\frac{1}{2} \sum_{i=1}^N \sum_{k=1}^K r_{ik} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 + \text{const}$$



课堂练习

- 考虑一组由 N 个样本组成的身高数据 $\{x_1, x_2, \dots, x_N\}$ ，由来自男生类簇（表示为类簇 C_1 ）和女生类簇（表示为类簇 C_2 ）的两组身高数据混合而成。其中，男生类簇的身高数据服从高斯分布 $N(\mu_1, \sigma_1^2)$ ，女生类簇的身高数据服从高斯分布 $N(\mu_2, \sigma_2^2)$ ，因此整个身高数据集服从混合高斯分布。
- 现在考虑使用期望最大化（Expectation Maximization，简称EM）算法来对这组身高数据进行“软”聚类。
 - 1) 请简述EM算法每次迭代中的Expectation步骤和Maximization步骤的主要目的，并给出这两个步骤的输入与输出；（4分）

课堂练习

- 假设某个Expectation步骤后，得到以下结果：

x_i	$P(C_1 x_i)$	$P(C_2 x_i)$
x_1 (174)	0.9	0.1
x_2 (173)	0.8	0.2
x_3 (168)	0.4	0.6
x_4 (167)	0.2	0.8
x_5 (166)	0.1	0.9

- 请计算接下来的Maximization步骤的内容：
 - 数据集中两个高斯分布的混合比例 $P(C_1)$ 和 $P(C_2)$ ？（2分）
 - 两个高斯分布的均值 μ_1 和 μ_2 ？列出计算式即可，可不计算出最终结果。（2分）
 - 两个高斯分布的方差 σ_1^2 和 σ_2^2 ？列出计算式即可，计算式中可以使用 μ_1 和 μ_2 ，可不计算出最终结果。（2分）



参考答案

- Expectation的目的是给每个样本一个软分配，其输入是两个高斯分布目前估计的参数（均值 μ_1 和 μ_2 、 σ_1^2 和 σ_2^2 ）以及混合比例（ $P(C_1)$ 和 $P(C_2)$ ），输出是软分配结果。
- Maximization的目的是根据目前样本的软分配，估计两个高斯分布的参数以及混合比例。
-
- $\alpha_1 = (0.9 + 0.8 + 0.4 + 0.2 + 0.1) / 5 = 2.4 / 5 = 0.48$
- $\alpha_2 = (0.1 + 0.2 + 0.6 + 0.8 + 0.9) / 5 = 2.6 / 5 = 0.52$
- $\mu_1 = (174 * 0.9 + 173 * 0.8 + 168 * 0.4 + 167 * 0.2 + 166 * 0.1) / 2.4$
- $\mu_2 = (174 * 0.1 + 173 * 0.2 + 168 * 0.6 + 167 * 0.8 + 166 * 0.9) / 2.6$
- $\sigma_1^2 = ((174 - \mu_1)^2 * 0.9 + (173 - \mu_1)^2 * 0.8 + (168 - \mu_1)^2 * 0.4 + (167 - \mu_1)^2 * 0.2 + (166 - \mu_1)^2 * 0.1) / 2.4$
- $\sigma_2^2 = ((174 - \mu_2)^2 * 0.1 + (173 - \mu_2)^2 * 0.2 + (168 - \mu_2)^2 * 0.6 + (167 - \mu_2)^2 * 0.8 + (166 - \mu_2)^2 * 0.9) / 2.6$

分类问题的基本步骤

Question → Data → Features → Algorithm → **Evaluation**

- 如何评价你分类器的优劣？
 - 能否直接在训练集评测？
 - **NO !**



预测结果

标准答案

	正例	负例
正例	12	3
负例	3	12

$$\text{Accuracy} = \frac{24}{30} = 80\%$$


分类问题的基本步骤

Question→Data→Features→Algorithm→**Evaluation**

- 如何评价你分类器的优劣？
 - 划分为训练集和测试集
 - **交叉验证**：K-fold cross validation

fold1	1	2	3	4	5	test accuracy1
fold2	1	2	3	4	5	test accuracy2
fold3	1	2	3	4	5	test accuracy3
fold4	1	2	3	4	5	test accuracy4
fold5	1	2	3	4	5	test accuracy5

平均



精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

标准答案	预测结果	
	正例	负例
	正例	负例
	8	12
	8	72

$$\text{Accuracy} = \frac{80}{100} = 80\%$$



看指标很不错
但总感觉哪里不对

- 几个关键概念

- True Positive (TP): 正确识别
- False Positive (FP): 错误识别
- True Negative (TN): 正确拒绝
- False Negative (FN): 错误拒绝



将**TP/FP/TN/FN**填到下表

标准答案	预测结果	
	正例	负例
	正例	负例

预测结果

混淆矩阵
Confusion
Matrix

精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

标准答案	预测结果	
	正例	负例
	正例	负例
	8	12
	8	72

$$\text{Accuracy} = \frac{80}{100} = 80\%$$



看指标很不错
但总感觉哪里不对

- 几个关键概念

- True Positive (TP): 正确识别
- False Positive (FP): 错误识别
- True Negative (TN): 正确拒绝
- False Negative (FN): 错误拒绝



将**TP/FP/TN/FN**填到下表

标准答案	预测结果	
	正例	负例
	正例	负例
	TP	FN
	FP	TN

精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

标准答案	预测结果	
	正例	负例
	正例	负例
	8	12
	8	72

$$\text{Accuracy} = \frac{80}{100} = 80\%$$



看指标很不错
但总感觉哪里不对

- 引入新的指标

- Precision – 准确率

$$\text{Precision} = \frac{TP}{TP + FP}$$

- Recall – 召回率

$$\text{Recall} = \frac{TP}{TP + FN}$$

- F1 Score - F值

$$F1 = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}}$$

请计算左表

精度（误差）的评测效果总是好吗？

- 使用测试集评测分类算法，结果如下：

		预测结果	
标准答案		正例	负例
	正例	8	12
	负例	8	72

$$\text{Accuracy} = \frac{80}{100} = 80\%$$



看指标很不错
但总感觉哪里不对

- 引入新的指标
 - Precision = 50%
 - Recall = 40%
 - F1 Score = 44%




实际分类效果很差！

分类算法的评测指标

• 课堂练习

考虑一个包含 22 个样本的数据集，其中有 11 个正例与 11 个负例。每个样本包含两个维度的特征，分别是 X_1 和 X_2 。使用者两个维度，可以 2 维平面上绘制散点图如下，其中坐标轴分别为 X_1 和 X_2 。



考虑仅使用维度 X_1 构造一个简单的分类器，如下：

- (1) 如果 $X_1 < \text{threshold}$ ，则预测样本为正例；
- (2) 如果 $X_1 \geq \text{threshold}$ ，则预测样本为负例。

其中 threshold 的位置如上图所示。

请根据以上情况回答：

(1) 请根据数据集和上述分类器，给出混淆矩阵，包括真阳性 (True Positive, 简称 TP)、假阳性 (False Positive, 简称 FP)、真阴性 (True Negative, 简称 TN) 和假阴性 (False Negative, 简称 FN) 的样本个数。(4 分)

(2) 计算上述分类器的精度 (Accuracy)。(3 分)

(3) 计算分类器的准确率 (Precision) 和召回率 (Recall) 和 F1 指标。(3 分)

提示：准确率、召回率和 F1 指标的计算公式如下：

$$\text{Precision} = \frac{TP}{TP+FP}, \quad \text{Recall} = \frac{TP}{TP+FN}, \quad \text{F1} = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}}$$




总结：数据建模的四个步骤

- **选择某种模型 – Model**
 - 回归模型 – Linear Regression
 - 分类模型 – Logistic Regression, Perceptron, SVM, Decision Tree
 - 聚类模型 – K-Means, GMM
- **选择目标函数 – Objective**
 - 经验分享最小 – Empirical Risk Minimization
 - 极大似然估计 – Maximum Likelihood Estimation
- **优化目标函数 – Optimization**
 - 最小化/最大化目标函数
- **评测模型效果 – Evaluation**
 - 评测指标



DS04 – 文本数据分析





LSI: 从单词-文档的共现矩阵开始



单词-文档共现矩阵可以为:

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...
ANTHONY	157	73	0	0	0	1	
BRUTUS	4	157	0	2	0	0	
CAESAR	232	227	0	2	1	0	
CALPURNIA	0	10	0	0	0	0	
CLEOPATRA	57	0	0	0	0	0	
MERCY	2	0	3	8	5	8	
WORSER	2	0	1	1	1	5	
...							

或者

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...
ANTHONY	5.25	3.18	0.0	0.0	0.0	0.35	
BRUTUS	1.21	6.10	0.0	1.0	0.0	0.0	
CAESAR	8.59	2.54	0.0	1.51	0.25	0.0	
CALPURNIA	0.0	1.54	0.0	0.0	0.0	0.0	
CLEOPATRA	2.85	0.0	0.0	0.0	0.0	0.0	
MERCY	1.51	0.0	1.90	0.12	5.25	0.88	
WORSER	1.37	0.0	0.11	4.15	0.25	1.95	
...							

词频

TF-IDF




LSI第一步：对单词-文档共现矩阵进行分解

$D =$

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...
ANTHONY	5.25	3.18	0.0	0.0	0.0	0.35	
BRUTUS	1.21	6.10	0.0	1.0	0.0	0.0	
CAESAR	8.59	2.54	0.0	1.51	0.25	0.0	
CALPURNIA	0.0	1.54	0.0	0.0	0.0	0.0	
CLEOPATRA	2.85	0.0	0.0	0.0	0.0	0.0	
MERCY	1.51	0.0	1.90	0.12	5.25	0.88	
WORSER	1.37	0.0	0.11	4.15	0.25	1.95	
...							

SVD (singular value decomposition): $D = U\Sigma V^T$

SVD得到的U、 Σ 、V



- $\Sigma = \begin{pmatrix} \sigma_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_R \end{pmatrix}$ 是对角方阵, $\sigma_1 \cdots \sigma_R$ 是 D 的 R 个非0特征根
- U 所有的列都正交: $\mathbf{u}_i^T \mathbf{u}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$, $\mathbf{u}_i$ 是 σ_i 对应左特征向量
- V 所有的列都正交: $\mathbf{v}_i^T \mathbf{v}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$, $\mathbf{v}_i$ 是 σ_i 对应右特征向量



SVD计算示例

$$D = U\Sigma V^T$$

- 待分解矩阵： $D = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{bmatrix}$

- 第一步：计算特征值和左特征向量U

- $DD^T = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 1 \end{bmatrix}$

- 进行特征分解 $(DD^T)\mathbf{u}_i = \sigma_i\mathbf{u}_i$ ，得到特征值为 $\sigma_1 = 3, \sigma_2 = 1, \sigma_3 = 0$ 和对应的特征向量

$\lambda = 3/1/0$

$$\mathbf{u}_1 = \begin{bmatrix} 1/\sqrt{6} \\ 2/\sqrt{6} \\ 1/\sqrt{6} \end{bmatrix}, \mathbf{u}_2 = \begin{bmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{bmatrix}, \mathbf{u}_3 = \begin{bmatrix} 1/\sqrt{3} \\ -1/\sqrt{3} \\ 1/\sqrt{3} \end{bmatrix}$$

- 舍弃特征值为0的向量， $U = \begin{bmatrix} 1/\sqrt{6} & 1/\sqrt{2} \\ 2/\sqrt{6} & 0 \\ 1/\sqrt{6} & -1/\sqrt{2} \end{bmatrix}$



SVD计算示例

$$D = U\Sigma V^T$$

第二步：计算右特征向量 V

1. $D^T D = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$

2. 基于非0特征值 $\sigma_1 = 3, \sigma_2 = 1$ ，进行特征分解 $(D^T D)v_i = \sigma_i v_i$ ，得到对应的特征向量 $v_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ $v_2 = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$

3. $V = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$

第三步：得到 Σ

1. $\Sigma = \text{diag}(\sqrt{\sigma_1}, \dots, \sqrt{\sigma_N})$ ，特征值开平方后组成对角阵


2. $D = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{bmatrix} = U\Sigma V^T = \begin{bmatrix} 1/\sqrt{6} & 1/\sqrt{2} \\ 2/\sqrt{6} & 0 \\ 1/\sqrt{6} & -1/\sqrt{2} \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 \\ 0 & \sqrt{1} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$

提问：为什么在第二步可以利用第一步特征分解得到的特征值3和1？

A: $D^T D$ 的非0特征值与 DD^T 的非0特征值一一对应，全部相等

B: 虽然 $D^T D$ 的特征值与 DD^T 并不相等，但为了计算简便，没有必要再算一次


LSI第二步：对特征根进行排序



- 原特征根矩阵 $\Sigma \rightarrow$ 排序后的特征根矩阵 Σ'
- $\Sigma' = \begin{pmatrix} \sigma_1' & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_R' \end{pmatrix}$, 其中 $\sigma_1' \geq \sigma_2' \geq \dots \geq \sigma_R'$
- 左特征向量矩阵也按照 Σ' 进行相应的调整
 - σ_i' 所对应的左特征向量调整到 U 的第 i 列
 - σ_i' 所对应的右特征向量调整到 V 的第 i 列
- 为表述简单：以下PPT中，依然用符号 U 、 Σ 、 V 表示调整后的矩阵



LSI第三步：只保留前K个特征值，其余置零



- 等号不再成立
- Σ_K ：只保留了前K个特征值的对角阵
- $\text{rank}(U \Sigma_K V^T) \leq \min(\text{rank}(U), \text{rank}(\Sigma_K), \text{rank}(V)) \leq K$
- 与文档/单词的数目而言，K比较小，如：K=50、100、200、500等
- $U \Sigma_K V^T$ 是D的低秩近似

取 $c=1$

$$\begin{pmatrix} \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{pmatrix} \sqrt{3} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}^T$$

3x1 1x2

3x2

回到之前的例子

	d_1	d_2	d_3	d_4	d_5
<i>romeo</i>	1	0	1	0	0
<i>juliet</i>	1	1	0	0	0
<i>happy</i>	0	1	0	0	0
<i>dagger</i>	0	1	1	0	0
<i>live</i>	0	0	0	1	0
<i>die</i>	0	0	1	1	0
<i>free</i>	0	0	0	1	0
<i>new-hampshire</i>	0	0	0	1	1

$$\Sigma = \begin{bmatrix} 2.285 & 0 & 0 & 0 & 0 \\ 0 & 2.010 & 0 & 0 & 0 \\ 0 & 0 & 1.361 & 0 & 0 \\ 0 & 0 & 0 & 1.118 & 0 \\ 0 & 0 & 0 & 0 & 0.797 \end{bmatrix}$$



$$\Sigma_2 = \begin{bmatrix} 2.285 & 0 \\ 0 & 2.010 \end{bmatrix}$$

回到之前的例子

$$\begin{array}{l} \textit{romeo} \\ \textit{juliet} \\ \textit{happy} \\ \textit{dagger} \\ \textit{live} \\ \textit{die} \\ \textit{free} \\ \textit{new-hampshire} \end{array} U_2 = \begin{bmatrix} -0.396 & 0.280 \\ -0.314 & 0.450 \\ -0.178 & 0.269 \\ -0.438 & 0.369 \\ -0.264 & -0.346 \\ -0.524 & -0.246 \\ -0.264 & -0.346 \\ -0.326 & -0.460 \end{bmatrix}$$

$$V_2^T = \begin{bmatrix} -0.311 & -0.407 & -0.594 & -0.603 & -0.143 \\ 0.363 & 0.541 & 0.200 & -0.695 & -0.229 \end{bmatrix}$$



回到之前的例子

$$romeo = \begin{bmatrix} -0.905 \\ 0.563 \end{bmatrix}, \quad juliet = \begin{bmatrix} -0.717 \\ 0.905 \end{bmatrix}, \quad happy = \begin{bmatrix} -0.407 \\ 0.541 \end{bmatrix}, \quad dagger = \begin{bmatrix} -1.001 \\ 0.742 \end{bmatrix},$$

$$live = \begin{bmatrix} -0.603 \\ -0.695 \end{bmatrix}, \quad die = \begin{bmatrix} -1.197 \\ -0.494 \end{bmatrix}, \quad free = \begin{bmatrix} -0.603 \\ -0.695 \end{bmatrix}, \quad new-hampshire = \begin{bmatrix} -0.745 \\ -0.925 \end{bmatrix},$$

$$d_1 = \begin{bmatrix} -0.711 \\ 0.730 \end{bmatrix}, \quad d_2 = \begin{bmatrix} -0.930 \\ 1.087 \end{bmatrix}, \quad d_3 = \begin{bmatrix} -1.357 \\ 0.402 \end{bmatrix}, \quad d_4 = \begin{bmatrix} -1.378 \\ -1.397 \end{bmatrix}, \quad d_5 = \begin{bmatrix} -0.327 \\ -0.460 \end{bmatrix}.$$

回到之前的例子

$$q = \frac{\begin{bmatrix} -1.197 \\ -0.494 \end{bmatrix} + \begin{bmatrix} -1.001 \\ 0.742 \end{bmatrix}}{2} = \begin{bmatrix} -1.099 \\ 0.124 \end{bmatrix}.$$


d1 : Romeo and Juliet.

d2 : Juliet: O happy dagger!

d3 : Romeo died by dagger.

d4 : "Live free or die", that's the New-Hampshire's motto.

d5 : Did you know, New-Hampshire is in New-England



将文档按照与q的cosine距离排序

A: d3 > d2 > d4 > d1 > d5

B: d3 > d1 > d2 > d4 > d5





朴素贝叶斯 (Naïve Bayes)

- 朴素贝叶斯属于概率分类器，给定一个文档 d ，其属于类别 c 的概率为

$$P(c|d) \propto P(c) \prod_{1 \leq k \leq n_d} P(t_k|c)$$

- n_d ：文档长度
- $P(t_k|c)$ ：给定类别 c ，出现单词 t_k 的概率
 - 通过单词 t_k 来度量类别 c 是否是文档 d 的正确类别
- $P(c)$ ：类别 c 的先验概率
 - 如果一个文档没有任何的迹象（单词）表明它属于类别 c 的概率要大于属于 c' 的概率，那么则选择先验概率较大的类别



最大化后验概率

- 朴素贝叶斯的目标
 - 为文档找到“最好”的类
- 什么是最好的类？
 - 能够最大化后验概率的类别 (maximum a posteriori (MAP) class), 记为 c_{map}

$$c_{\text{map}} = \arg \max_{c \in \mathcal{C}} \hat{P}(c|d) = \arg \max_{c \in \mathcal{C}} \hat{P}(c) \prod_{1 \leq k \leq n_d} \hat{P}(t_k|c)$$

朴素贝叶斯训练算法

TRAINMULTINOMIALNB($\mathbb{C}, \mathbb{D}$)

```
1   $V \leftarrow \text{EXTRACTVOCABULARY}(\mathbb{D})$ 
2   $N \leftarrow \text{COUNTDOCS}(\mathbb{D})$ 
3  for each  $c \in \mathbb{C}$ 
4  do  $N_c \leftarrow \text{COUNTDOCSINCLASS}(\mathbb{D}, c)$ 
5      $\text{prior}[c] \leftarrow N_c / N$ 
6      $\text{text}_c \leftarrow \text{CONCATENATETEXTOFALLDOCSINCLASS}(\mathbb{D}, c)$ 
7     for each  $t \in V$ 
8     do  $T_{ct} \leftarrow \text{COUNTTOKENSOFTERM}(\text{text}_c, t)$ 
9     for each  $t \in V$ 
10    do  $\text{condprob}[t][c] \leftarrow \frac{T_{ct}+1}{\sum_{t'} (T_{ct'}+1)}$ 
11 return  $V, \text{prior}, \text{condprob}$ 
```

朴素贝叶斯应用/测试

```
APPLYMULTINOMIALNB( $\mathbb{C}$ ,  $V$ ,  $prior$ ,  $condprob$ ,  $d$ )  
1   $W \leftarrow \text{EXTRACTTOKENSFROMDOC}(V, d)$   
2  for each  $c \in \mathbb{C}$   
3  do  $score[c] \leftarrow \log prior[c]$   
4      for each  $t \in W$   
5      do  $score[c] + = \log condprob[t][c]$   
6  return  $\arg \max_{c \in \mathbb{C}} score[c]$ 
```




图数据分析

- 基本内容：**CCI**
 - **Centrality**：图里的哪些节点更重要？
 - **Community**：图是否能够划分为不同的社区？
 - **Influence**：图中的信息是如何传播的，谁是传播关键节点？

三种Centrality度量的比较

- 请分别指出Degree, Closeness和Betweenness Centrality最大的节点



网络各个节点的中心性					
Degree		Closeness		Betweenness	
Diane	0.667	Fernando	0.643	Heather	0.389
Fernando	0.556	Garth	0.643	Fernando	0.231
Garth	0.556	Diane	0.600	Garth	0.231
Andre	0.444	Heather	0.600	Ike	0.222
Beverly	0.444	Andre	0.529	Diane	0.102
Carol	0.333	Beverly	0.529	Andre	0.023
Ed	0.333	Carol	0.500	Beverly	0.023
Heather	0.333	Ed	0.500	Carol	0.000
Ike	0.222	Ike	0.429	Ed	0.000
Jane	0.111	Jane	0.310	Jane	0.000

- 扩展学习：Eigenvector Centrality （与PageRank算法很相关）
<https://www.geeksforgeeks.org/eigenvector-centrality-centrality-measure/>

PageRank算法

- 迭代公式

$$p_i = \frac{1 - \alpha}{n} + \alpha \sum_{j \rightarrow i} \frac{p_j}{m_j} = \frac{1 - \alpha}{n} + \alpha \sum_{j=1}^n \frac{L_{ji}}{m_j} p_j$$

$$p = \alpha \mathbf{pL} + \frac{1-\alpha}{n} \mathbf{pE}, E \text{ is the } n \times n \text{ matrix of 1s}$$
A red arrow points from the text below to the alpha parameter in the matrix equation above.

α : Damping parameter, 经验上取0.85

- PageRank计算的过程也称随机游走 (Random Walk)

Personalized PageRank

- 在在前面计算的公式的基础上做了“微小”改动

$$p_i = (1 - \alpha)p_i^{(0)} + \alpha \sum_{j \rightarrow i} \frac{p_j}{m_j} = (1 - \alpha)p_i^{(0)} + \alpha \sum_{j=1}^n \frac{L_{ji}}{m_j} p_j$$

$$p = \alpha \mathbf{pL} + (1 - \alpha) \mathbf{p}^{(0)}$$



α : Damping parameter, 经验上取0.85

- 计算的过程也称Random Walk with Restart



社区检测优化目标：Modularity Q


- 定义Modularity函数

$$Q(G, S) = \frac{1}{2m} \sum_{s \in S} \sum_{i \in s} \sum_{j \in s} \left(A_{ij} - \frac{k_i k_j}{2m} \right)$$

- Modularity函数的范围是 $[-1, 1]$
- Modularity函数大于0.3-0.7，成为“显著社区结构”（significant community structure）
- 社区发现的思路之一：优化modularity函数

Modularity Q

- 计算下面划分 s 的Modularity



A. $-\frac{1}{16}$ B. $\frac{5}{36}$ C. $\frac{1}{6}$

$$Q(G, S) = \sum_{s \in S} \frac{\sum_{i,j} A_{ij}}{2m} - \frac{1}{2m} \sum_{i,j} \frac{k_i k_j}{2m}$$

简便起见，不考虑自环边

$$= \sum_{s \in S} \frac{\sum_{i < j} A_{ij}}{m} - \left(\frac{\sum_{i \in s} k_i}{2m} \right)^2$$

$$= \sum_{s \in S} \frac{\sum_{in}}{m} - \left(\frac{\sum_{tot}}{2m} \right)^2$$

简便起见，引入符号 $\sum_{in}$ 和 $\sum_{tot}$

$$Q(G, S) = \frac{1}{2m} \sum_{s \in S} \sum_{i \in s} \sum_{j \in s} \left(A_{ij} - \frac{k_i k_j}{2m} \right)$$


Louvain算法

- Phase 1：以局部方式，优化模块度函数，将每个顶点归到“最好”的类簇中，直到所有的顶点所属的类簇不再变化为止 – **one_level**
- 如何计算将*i*合并到社区*C*中的modularity增益 ΔQ ？



请计算 $\Delta Q(i \rightarrow C)$

A. $\frac{1}{16}$ B. $\frac{1}{24}$ C. $\frac{1}{6}$



节点*i*连接到*C*的边数

$$\Delta Q(i \rightarrow C) = \left\{ \frac{\Sigma_{in} + k_{i,in}}{m} - \left(\frac{\Sigma_{tot} + k_i}{2m} \right)^2 \right\} - \left\{ \frac{\Sigma_{in}}{m} - \left(\frac{\Sigma_{tot}}{2m} \right)^2 - \left(\frac{k_i}{2m} \right)^2 \right\}$$

$$= \frac{1}{m} \left\{ k_{i,in} - \frac{k_i \cdot \Sigma_{tot}}{2m} \right\}$$

节点*i*的度数




Louvain算法

- Phase 1 : 以局部方式, 优化模块度函数, 将每个顶点归到 “最好” 的类簇中, 直到所有的顶点所属的类簇不再变化为止 – **one_level**
- 如何计算将 i 合并到社区 C 中的modularity增益 ΔQ ?
 - 计算 $\Delta Q(i \rightarrow C)$
 - 计算 $\Delta Q(D \rightarrow i)$, 即将节点 i 移除原本的社区 D
 - 请你推导 $\Delta Q(D \rightarrow i)$
 - $\Delta Q = \Delta Q(i \rightarrow C) + \Delta Q(D \rightarrow i)$


Louvain算法

- Phase 2 : 把一个类簇中的所有顶点聚集抽象为一个**超级顶点**，重建一个网络，其中的每个顶点对应一个社区 - **induced_graph**



Independent Cascades模型

- 影响力最大化Influence Maximization
 - 找到信息传播中的“关键种子节点”




思考：

如果只让你选择2个种子节点，你会怎么选？

影响力最大化 (Influence Maximization)

- 影响力最大化 Influence Maximization
 - 找到信息传播中的 “关键种子节点”
- 这个问题有多复杂？
 - NP难问题：不存在一个时间复杂度与节点个数呈多项式关系的算法
- 计算任意 k 个点 S 的影响力 $\sigma(S)$
 - 需要模拟多次之前的IC模型
 - 时间复杂度高 (#P难问题)





Degree Discount算法

Algorithm DegreeDiscountIC(G, k)

```
1: initialize  $S = \emptyset$ 
2: for each vertex  $v$  do
3:   compute its degree  $d_v$ 
4:    $dd_v = d_v$ 
5:   initialize  $t_v$  to 0
6: end for
7: for  $i = 1$  to  $k$  do
8:   select  $u = \arg \max_v \{dd_v \mid v \in V \setminus S\}$ 
9:    $S = S \cup \{u\}$ 
10:  for each neighbor  $v$  of  $u$  and  $v \in V \setminus S$  do
11:     $t_v = t_v + 1$ 
12:     $dd_v = d_v - 2t_v - (d_v - t_v)t_v p$ 
13:  end for
14: end for
15: output  $S$ 
```

原论文扩展阅读:

https://www.microsoft.com/en-us/research/uploads/prod/2016/06/kdd09_influence-1.pdf

思考：如果边上的概率不都等于 p 呢？



Degree Discount算法的扩展

- 如何支持增量计算：为每个节点 v 维护两个变量
 - pp_v ：用来表示节点 v 没有被感染的概率，即公式中左侧的方框
 - d_v ：用来表示节点 v 可以影响的邻居的期望个数，即公式中左侧的方框
- 初始化：
 - $pp_v \leftarrow 1$ ：表示目前节点 v 没有被感染
 - $d_v \leftarrow 1 + \sum_{w \in N} p_{v \rightarrow w}$ ，其中 N 是节点 v 所有的Out-neighbors
- 更新：如果节点 v 的某个邻居 w 加入到了种子集合，则做更新操作：
 - $pp_v \leftarrow pp_v \cdot (1 - p_{w \rightarrow v})$
 - $d_v \leftarrow d_v - p_{v \rightarrow w}$
 - 根据以上两项更新 $\Delta\sigma(S)$


$$\Delta\sigma(S) = \prod_{u \in S_v} (1 - p_{u \rightarrow v}) \cdot \left(1 + \sum_{w \in N_v} p_{v \rightarrow w} \right)$$



数据科学家应具备什么能力

- 管理和处理各种类型的数据
- 解决数据科学的两个核心任务
 - 从数据中洞见真知
 - 基于数据驱动进行决策支持
- 掌握数据分析的技能与工具
- 能够处理大规模的数据
- 了解数据伦理问题

最后轻松一下.....






二战时图灵的“游戏”

- 这个游戏很简单，每一封德国电报，每一次突然袭击，每一次炸弹轰炸，每一次U艇攻击，都在空中无线传输着，那些无线信号，任何有一台调幅装备的小学生都能截获。
- 困难之处在于，他们都是加密过的，并且有一千五百万万亿种，可能的恩尼格码设定，我们的任务就是尝试每种可能性，但是如果十个人检验一种设定，每天二十四小时，每周七天不停，试完每种组合，需要多少天呢？不是多少天，而是多少年，需要两千万年，想要阻止一场袭击，我们必须在20分钟内，试完两千万年才能试完的设定。

二战时图灵的“游戏”



三个转子可以提供10万个密钥，通过插线板进一步将密钥数量扩展为 10^{16} 。如果用暴力破解的话，就算一秒钟验算一万个密钥，要3万多年才能穷尽所有可能。而德军的一条密钥使用时间只有24个小时.....

二战时图灵的“游戏”



图灵设计的

“炸弹”（Bombe）

三个一组的转盘，每个转盘相当于一个转子，每组转盘相当于一台恩格玛机

利用机器对可能的情况进行枚
举，并利用一些特定规则裁减掉不可能的情况

如果遇到可能的解，机器就会停下来供工作人员记录结果



你们的游戏.....



数据科学导论期末考试

- 更关键的是.....
 - Be a Problem Solver, and...
 - Enjoy your game!